

天津大学

本科生毕业论文



题目：生物气囊基因线路模块化设计与可视化仿真

学 院	智能与计算学部
专 业	计算机科学与技术
年 级	2022 级
姓 名	王嘉仑
学 号	3022244358
指导教师	宫秀军

独创性声明

本人声明：所呈交的毕业设计（论文），是本人在指导教师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本毕业设计（论文）中不包含任何他人已经发表或撰写过的研究成果。对本毕业设计（论文）所涉及的研究工作做出贡献的其他个人和集体，均已在论文中作了明确的说明。本毕业设计（论文）原创性声明的法律责任由本人承担。

论文作者签名：王嘉伦

2026 年 5 月 31 日

本人声明：本毕业设计（论文）是本人指导学生完成的研究成果，已经审阅过论文的全部内容。

论文指导教师签名：宫秀军

2026 年 5 月 31 日

摘要

随着合成生物学和系统生物学的发展，生物气囊基因线路的设计与仿真成为研究基因功能及其调控机制的重要手段。然而，现有研究多聚焦于气囊基因簇功能解析、基因线路自动化设计、表达性能预测等单一环节，缺少面向生物气囊基因线路的设计、预测、动力学仿真与可视化分析一体化平台，难以支持复杂基因网络的综合研究与工程化设计。针对上述问题，本文开发了一个功能全面的气囊基因线路设计与仿真结果可视化系统，实现了从基因线路建模、动态仿真到结果可视化的完整流程。系统基于常微分方程构建基因线路动力学模型，支持转录、翻译、降解等基本过程，并涵盖激活、抑制等调控机制。用轻量级岭回归模型来预测启动子、核糖体结合位点、编码序列和终止子组合的表达强度，将预测结果映射到线路仿真参数上。并通过集成多种可视化技术，包括 2D/3D 网络图、动态表达曲线、参数敏感性分析和路径分析，系统能够直观展示基因网络的拓扑结构和动态行为。实验结果表明，该系统在性能、交互性和功能性方面表现优异，能够有效支持气囊基因线路的研究与设计，并为相关领域的基因线路分析提供了可扩展的工具框架。

关键词： 生物气囊，基因线路设计，岭回归，动态仿真，可视化分析

ABSTRACT

With the development of synthetic biology and systems biology, the design and simulation of gas vesicle gene circuits have become important approaches for studying gene functions and regulatory mechanisms. However, existing research mainly focuses on individual aspects such as gas vesicle gene cluster characterization, automated gene circuit design, and expression performance prediction. There remains a lack of an integrated platform that combines gene circuit design, expression prediction, dynamic simulation, and visualization analysis for gas vesicle gene circuits, which limits comprehensive studies and engineering applications of complex gene regulatory networks.

To address these challenges, this paper develops a comprehensive visualization system for gas vesicle gene circuit design and simulation. The system implements a complete workflow covering gene circuit modeling, dynamic simulation, and result visualization. An ordinary differential equation (ODE)-based dynamic model is constructed to describe fundamental biological processes, including transcription, translation, and degradation, while also incorporating activation and repression regulatory mechanisms. A lightweight Ridge Regression model is employed to predict the expression strength of combinations of promoters, ribosome binding sites (RBSs), coding sequences (CDSs), and terminators, and the prediction results are further mapped to simulation parameters for gene circuit analysis.

In addition, the system integrates multiple visualization techniques, including 2D/3D network graphs, dynamic expression curves, parameter sensitivity analysis, and pathway analysis, enabling intuitive presentation of both the topological structures and dynamic behaviors of gene regulatory networks. Experimental results demonstrate that the proposed system exhibits excellent performance, interactivity, and functionality. It effectively supports the research and design of gas vesicle gene circuits and provides an extensible framework for gene circuit analysis in related fields.

KEY WORDS: Gas Vesicle ; Gene Circuit Design ; Ridge Regression ; Dynamic Simulation; Visualization Analysis

目 录

第一章 绪论	1
1.1 课题背景与研究意义	1
1.1.1 生物气囊的结构特性与应用价值	1
1.1.2 生物气囊基因线路设计的主要挑战	2
1.1.3 本研究的理论意义与实际应用价值	2
1.2 国内外研究现状	2
1.2.1 国内研究现状	2
1.2.2 国外研究现状	3
1.3 本文组织结构与研究内容	4
第二章 理论基础与关键技术	5
2.1 相关理论基础	5
2.1.1 生物气囊形成机制与 gvp 基因簇功能	5
2.1.2 基因元件调控原理	5
2.1.3 基因表达的动力学模型	5
2.2 表达性能预测与平台开发关键技术	6
2.2.1 元件组合特征工程	6
2.2.2 岭回归预测模型	7
2.2.3 可视化仿真平台开发技术	7
第三章 实验设计流程	8
3.1 总体架构设计	8
3.2 数据收集、预处理与标准化	9
3.2.1 原始数据采集与字段整理	9
3.2.2 序列去冗余与统一命名	10
3.2.3 标准化数据集构建与输出	11
3.3 生物气囊基因线路设计	11
3.3.1 调控元件库建立	11
3.3.2 元件性能参数量化与组合规则建立	12
3.3.3 调控关系与参数映射方法	12
3.4 表达性能预测模型构建	13
3.4.1 特征向量构造	13

3.4.2	基于岭回归的组合性能预测	13
3.4.3	高表达候选筛选与排序	14
3.5	可视化仿真平台开发	14
3.5.1	参数设置功能	14
3.5.2	主页面功能	14
3.6	参数调优与模型校准	16
3.6.1	参数范围设定与调优策略设计	16
3.6.2	正则化系数、筛选阈值与仿真参数调优	16
3.6.3	最优参数组合确定与依据说明	18
第四章	实验结果分析	19
4.1	实验环境与数据基础	19
4.1.1	验证环境说明	19
4.1.2	数据规模与元件库统计	19
4.2	整体性能分析	19
4.2.1	最优参数组合与整体预测结果	19
4.2.2	平台运行效率与资源占用情况	21
4.3	模型评价指标分析	21
4.3.1	回归拟合效果分析	21
4.3.2	高表达分类准确性分析	21
4.3.3	RMSE、 R^2 、准确率与 F1 分数解释	21
4.4	典型组合案例分析	21
4.4.1	高表达组合仿真结果	21
4.4.2	平衡表达组合仿真结果	22
4.4.3	低负荷组合仿真结果	22
4.5	消融实验	22
4.5.1	不同元件特征对预测结果的影响	22
4.5.2	关键特征贡献分析	23
4.6	对比实验	23
4.6.1	平台枚举最优方案与传统手工方案对比	24
4.6.2	随机筛选方案与约束筛选方案对比	24
4.6.3	不同设计策略的适用场景分析	24
4.7	可视化平台功能验证	25
4.7.1	调控网络结构展示效果	25
4.7.2	动态仿真曲线展示	26

4.7.3 参数分析与数据管理展示效果	27
第五章 结论与展望	34
5.1 实验结论	34
5.2 现存不足	34
5.3 未来展望	34
参考文献	36
致 谢	38

第一章 绪论

生物气囊（Gas Vesicle）最初被认识为蓝藻、古菌和部分细菌的浮力调节结构^[1]。随着合成生物学和超声分子影像技术的发展，GV 逐渐由天然生态结构转变为可编码、可调控、可读出的蛋白纳米结构。与荧光蛋白相比，GV 的声学信号穿透深度更高，与外源纳米材料相比，GV 可以通过基因表达在细胞内原位形成，因此在活体细胞追踪、工程菌治疗监测和肿瘤微环境探测中具有独特价值^[2]。

但是，气囊表型并不是某一个结构基因的单独结果，而是多个 gvp 基因、调控元件、宿主背景和装配过程共同作用的结果^[3]。本文不把 GV 线路看作简单的单基因表达问题，而是将其抽象为包含数据标准化、模块组合、表达预测、ODE 仿真和可视化验证的工程系统。

1.1 课题背景与研究意义

1.1.1 生物气囊的结构特性与应用价值

从工程实现角度看，GV 的价值并不只体现在最终声学信号上，还体现在其形成过程可以被拆分为若干可调环节^[4]。结构蛋白的表达量决定壳体材料供给，辅助蛋白影响壳体装配质量，调控元件决定不同基因之间的表达比例。也就是说，GV 是一种天然适合被线路化处理的蛋白纳米结构。本文选择以基因线路为切入点，是因为线路层面的改动比直接修改每一个蛋白结构更容易形成系统化的设计规则，也更容易用软件平台进行参数扫描和方案比较。

此外，GV 的应用场景对设计工具提出了较高要求。若目标是细胞示踪，需要输出信号稳定且宿主负担较低；若目标是增强超声对比，需要较高的气囊形成效率和较强的壳体稳定性；若目标是环境响应型探针，则需要将输入信号与 gvp 表达连接起来。不同目标并不共享同一个最优组合，因此平台必须能够保留多种候选并显示其差异，而不能只给出单一分数最高的方案。

GV 由 GvpA 等疏水结构蛋白形成基本壳体，GvpC 等辅助蛋白参与增强壳体稳定性，GvpN、GvpF、GvpG、GvpJ、GvpK 等成员则与装配过程相关。该类结构内部为空气相，外壁由高度有序的蛋白网络构成，能够在超声场下产生可识别的回波。对于生物医学应用而言，GV 的优势在于其信息载体是基因，可以通过工程化线路被细胞主动表达，而不需要外源颗粒持续输入。

1.1.2 生物气囊基因线路设计的主要挑战

GV 线路设计的首要难点是组合空间快速膨胀。项目元件库中启动子、RBS、CDS 和终止子各 8 个，仅单目标基因的四元件组合就达到 4096 种。若进一步考虑 15 个可计算 gvp 节点的表达比例、调控边和宿主负担，传统依靠经验逐个试错的方法很难覆盖有效搜索空间；过强表达也可能增加代谢负担并破坏蛋白比例。

第二个挑战是数据粒度不一致。FASTA 序列提供具体序列记录，单基因元数据提供来源、长度和注释，锚定上下文汇总表更偏向基因簇附近的组织关系。若不区分这些粒度，就容易把序列记录数、汇总记录数和模型节点数混用。本文在修订中统一数据口径，把单基因元数据、汇总上下文记录、FASTA 记录和模型节点分别说明，保证后续图表和结论能够相互对应。

模型层面的挑战在于简化和真实性之间的平衡。本文先保证表达调控和元件组合链路可运行、可解释、可视化，后续再逐步加入蛋白折叠、宿主资源竞争、气囊塌陷压力和超声散射等更细的生物物理机制；因此正文统一采用对数终值、相对倍数和曲线趋势解释仿真结果，避免把无量纲输出误读为湿实验浓度。

1.1.3 本研究的理论意义与实际应用价值

理论上本研究把 GV 蛋白纳米结构、基因调控网络和机器学习表达预测放在同一条计算链路中，强调设计决策必须同时具有数据来源、参数含义和仿真后果。实际应用上，平台可以在湿实验前完成候选组合排序、关键参数敏感性分析和路径解释，帮助研究者把有限实验资源集中在更有信息量的方案上。

1.2 国内外研究现状

1.2.1 国内研究现状

国内有关生物气囊及工程化应用的研究开始得比较晚，但是近几年来已经由基础结构的介绍转向了医学成像、环境响应和智能设计方法的融合等方向。有学者认为气囊不是普通的超声材料，是由可遗传编码的纳米级中空蛋白壳体构成的，具有可表达、可调控、可功能化等特点，可以用于医学成像、靶向治疗、疫苗递送、多模态探针的开发^[5]。该类研究确定 GvpA 是气囊壳体形成的中心结构蛋白，GvpC 可以加强壳体的稳定性，不同的 gvp 成员在气囊形成及功能调节上起着不同的作用^[6]。由此可以看出生物气囊的工程设计不能只看单

个基因的表达强弱，而应该从基因簇的整体结构、表达比例、装配过程等角度来建立模型。

部分研究 pH 对生物合成超声分子影像探针气囊充放气的影响做了相关工作，得出环境 pH 会影响微囊藻细胞内气囊及提纯气囊的充放气情况，给气囊保存、气体更换以及诊疗应用提供实验依据^[7]。该类工作表明，GV 作为成像探针时，它的最终表型受基因表达的控制，也受外部环境因素的影响。因此，在创建气囊基因线路仿真平台的时候，除了转录、翻译、降解这些基本过程之外，还要给 pH、压力、超声信号等外界变量留有扩充接口^[8]。

部分研究认为大语言模型可以用于序列—功能映射、基因元件设计、基因线路构建、基因簇重构，但是也存在数据质量、模型可解释性、实验闭环、生物安全等问题^[9]。该研究给生物气囊线路的设计提供新的思路，即可以利用蛋白语言模型或者大模型来辅助候选的生成以及序列特征的提取^[10]。但是目前阶段 GV 线路的设计仍然要依靠可以解释、可以校准和可以实验复核的计算模型。国内研究已经开始注意到 GV 在医学方面的应用价值以及智能设计的能力，但是对基因线路层面的模块化建模、表达性能预测以及可视化仿真工具等还没有形成完整的流程。

1.2.2 国外研究现状

国外对于生物气囊的研究起步较早，已经形成了一个从结构生物物理、基因簇功能解析到工程化调控、计算设计比较完整的脉络。Ghosh 较早地对气囊作为微生物浮力调节结构的形态、蛋白壳体、气体通透性、临界塌陷压力以及生态功能进行了系统的总结，为 GV 生物物理的研究打下了基础^[12]。随着合成生物学、超声分子影像的发展，GV 渐渐成为一种可以被编码的声学报告基因以及蛋白纳米结构。Fu 等人利用异源表达系统研究 GV 基因簇成员对气囊形态和超声成像性能的影响，发现某些 gvp 基因的删除或者组合调控可以改变气囊的大小、形状以及声学输出，在老鼠肝脏中可以获得较好的超声对比信号^[13]。因此 GV 基因簇不是固定的黑箱，而是可以被编辑、组合、优化的功能模块集合。

基因线路自动化设计上，Matthay 等提出的 Cello 2.0 把抽象逻辑功能、标准化生物元件、数学模型、DNA 序列设计联系成一个自动化过程，从而把逻辑需求转变成遗传线路^[14]。虽然 GV 线路更偏向连续表达调控和蛋白装配表型，但是它的设计仍然依靠元件标准化、组合空间搜索和性能预测。Das 等开发的 Gene Circuit Explorer 更加注重基因调控网络的交互式可视化、ODE 仿真、参数

扰动以及实验数据的比较^[15]，说明现代基因线路研究已经不再满足于静态拓扑的展示，而是更加强调动态的行为、参数的敏感性以及可以被复核的分析。

AlphaFold、蛋白语言模型、ESMFold 等研究促进了蛋白结构和功能预测的发展，给之后将 Gvp 蛋白结构置信度、折叠稳定性、装配界面特征加入表达预测模型打下了基础。Sheervalilou 等提出的 SBML 标准给生化网络模型的共享、复现提供了一个统一的表达方式^[16]。从总体上看，国外对于 GV 基础机制、基因簇工程化、线路自动设计、动态仿真以及模型标准化等方面已经有了较多的研究成果，但是针对 GV 基因线路的“一体化设计-预测-仿真-可视化”的工具还存在着整合的空间。本文是在上述研究的基础上，把 gvp 基因簇、调控元件组合、岭回归表达预测、ODE 动力学仿真、可视化分析整合到同一个平台上，给生物气囊基因线路的计算设计提供原型支持。

1.3 本文组织结构与研究内容

本文围绕“数据整理—线路建模—表达预测—可视化仿真”四个环节组织研究内容。首先整理 17 类 gvp 单基因元数据、17 个 FASTA 序列文件、79 条锚定上下文汇总记录 and 32 个调控元件，明确不同数据表之间的口径差异；接着以 GasVesicleCircuit 类描述 15 个可计算基因节点、转录速率 α 、翻译速率 β 、降解速率 γ 和调控矩阵；然后通过 ModularElementLibrary 读取元件库，并用 RidgeExpressionPredictor 完成表达评分；最后在 Streamlit 平台中集成线路结构图、表达动态、参数分析、路径分析、模型验证、数据管理和报告生成等功能。

全文共五章。第一章说明研究背景与意义、国内外研究现状和本文研究内容；第二章介绍 GV 线路建模、表达性能预测、可视化仿真等相关理论基础与关键技术；第三章按程序实现流程依次说明总体架构、数据处理、线路设计、预测模型、平台开发和参数校准；第四章给出实验整体性能与相关结果分析、消融实验和对比实验等；第五章总结系统价值、现存不足和后续改进方向。

第二章 理论基础与关键技术

2.1 相关理论基础

2.1.1 生物气囊形成机制与 gvp 基因簇功能

生物气囊的形成依赖 gvp 基因簇成员协同表达。不同基因功能明确、分工协作：GvpA、GvpC 为核心结构蛋白，构成气囊壳体骨架并增强稳定性；GvpF、GvpG、GvpJ、GvpK、GvpN 参与气囊装配、形态调控与成熟过程；调控相关基因则主导 gvp 基因时序表达，决定气囊大小、稳定性及声学信号强度。

气囊表型并非单一基因表达的结果，而是多基因协同、元件调控、宿主背景、装配过程共同作用的复杂表型。因此，对本实验而言，需要把基因功能转换成可计算节点和调控边，需将其抽象为可量化、可仿真的基因调控网络，实现工程化设计与优化。

2.1.2 基因元件调控原理

基因表达由启动子、核糖体结合位点（RBS）、编码序列（CDS）、终止子四类核心元件逐级调控，各元件特性直接决定转录、翻译效率与表达稳定性，是基因线路设计的核心模块。

启动子决定转录起始强度，直接影响 mRNA 生成速率；RBS 决定翻译起始强度，影响蛋白合成速率；CDS 的序列特性决定蛋白结构、折叠效率与密码子适配性，进而影响翻译效率与蛋白稳定性；终止子则影响转录终止效率与 mRNA 表达稳定性。

四类元件的组合效应是决定基因表达水平的关键，本研究将四类元件均用 strength 字段量化，并在组合预测中加入启动子×RBS、CDS×终止子和启动子×CDS 交互项，用于模型输入与参数映射。

2.1.3 基因表达的动力学模型

基因线路动态行为通过常微分方程（ODE）建模，描述 mRNA 与蛋白浓度随时间的变化规律，核心包含转录、翻译、降解、调控四类过程。对第 i 个基因来说，mRNA 浓度用 m_i 表示，蛋白浓度用 p_i 表示，基础转录速率为 α_i ，翻译速率为 β_i ，降解速率为 γ_i ，调控矩阵权重为 w_{ij} ，则动力学方程写作：

$$\frac{dm_i}{dt} = \alpha_i + \sum_{j=1}^n w_{ij} p_j - \gamma_i m_i \quad \# (2-1)$$

$$\frac{dp_i}{dt} = \beta_i m_i - \gamma_i p_i \quad \# (2-2)$$

其中调控矩阵为 $n \times n$ 维度（ n 为基因数量），行代表调控基因，列代表被调控基因， w_{ij} 大于 0 表示激活、小于 0 表示抑制、等于 0 表示无调控。

对于多基因引入调控优化基础模型，激活型调控采用希尔函数描述：

$$\alpha'_i = \alpha_i \times \left(1 + \frac{k \times [\text{Regulator}]^n}{K^n + [\text{Regulator}]^n} \right) \quad \# (2-3)$$

抑制型调控为：

$$\alpha'_i = \alpha_i \times \left(1 - \frac{k \times [\text{Regulator}]^n}{K^n + [\text{Regulator}]^n} \right) \quad \# (2-4)$$

其中 α'_i 为调控后转录速率，Regulator 为调控因子浓度， n 为希尔系数（反映调控协同性，取值 1-4）， K 为解离常数（反映调控因子与启动子的结合能力）， k 为调控强度系数。

2.2 表达性能预测与平台开发关键技术

2.2.1 元件组合特征工程

为实现“元件组合 — 表达强度”的精准映射，元件组合被编码为 9 维特征向量：包括四类元件强度、三个交互项、跨物种惩罚项和偏置项。特征向量写作：

$$\mathbf{x} = [s_p, s_r, s_c, s_t, s_p s_r, s_c s_t, s_p s_c, q, 1]^T \quad \# (2-5)$$

其中 s_p 、 s_r 、 s_c 、 s_t 分别表示启动子、RBS、编码序列、终止子的强度； $s_p s_r$ 、 $s_c s_t$ 、 $s_p s_c$ 为元件交互项，描述元件间协同效应； q 为跨物种惩罚项；1 为偏置项。

特征工程的核心思想是把生物元件的选择转换为模型可处理的数值。四个基础强度特征对应最直接的表达影响，交互项用于表达元件之间的协同关系，跨物种惩罚用于表达来源不一致可能带来的适配风险。该设计虽然简单，但具有较强可解释性：当预测结果升高或降低时，可以回到具体元件和特征贡献进行分析，而不是只得到一个无法解释的黑箱输出。

在实际使用中，特征向量还承担连接预测模型和 ODE 模型的桥梁作用。预测模型只需要特征向量给出表达评分，而 ODE 仿真需要把该组合转化为 α 、 β 和 γ 参数。程序通过 `simulate_design_in_circuit` 函数完成这种连接，使元件库不只是静态表格，而是能够影响动态仿真的参数来源。

2.2.2 岭回归预测模型

由于元件库规模较小，特征间存在共线性，传统复杂模型易过拟合，本文采用岭回归而不是复杂深度模型。岭回归通过 L2 正则化限制系数过大，适合处理启动子、RBS、CDS 和交互项之间可能存在的共线性问题。岭回归的损失函数为：

$$L(\theta) = \sum_{i=1}^n (y_i - x_i^T \theta)^2 + \lambda \|\theta\|_2^2 \quad (2-6)$$

其中 y_i 为第 i 个样本的真实表达强度； x_i 为第 i 个样本的 9 维特征向量； θ 为模型系数向量； λ 为正则化系数； N 为训练样本数。

模型求解采用闭式解，避免迭代优化的效率损耗：

$$\theta = (X^T X + \lambda I)^{-1} X^T y \quad (2-7)$$

其中 X 为特征矩阵， y 为真实表达强度向量； I 为单位矩阵。

模型训练完成后，输入任意元件组合的特征向量，即可输出标准化表达评分，实现元件组合的快速筛选与排序。

2.2.3 可视化仿真平台开发技术

平台前端采用 Streamlit，网络结构使用 NetworkX、Matplotlib 与 Plotly 展示，曲线、热力图和雷达图用于表达动态与参数敏感性分析。可视化不只是结果展示，也承担参数编辑、模板保存、实验数据上传和报告导出的交互入口。

代码 2-1 Streamlit 主页面功能标签

```
main_tabs = st.tabs([
    "线路结构图",
    "表达动态",
    "参数分析",
    "路径分析",
    "模型验证",
    "数据管理",
    "报告生成",
    "图表中心"
])
```

第三章 实验设计流程

3.1 总体架构设计

系统总体架构从数据标准化开始。FASTA 文件提供序列主体，单基因元数据 CSV 提供 accession、gene_name、organism、sequence_length 等字段，调控元件 CSV 提供 element_id、species、strength、sequence 和 description 等信息。程序读取并清洗这些文件后，形成统一命名、统一字段和统一强度尺度的数据集，作为后续特征构造和仿真参数设置的输入。

计算流程分为预测路线和仿真路线。预测路线以启动子、RBS、CDS 和终止子强度为基础，加入启动子×RBS、CDS×终止子、启动子×CDS 等交互项以及跨物种惩罚，构成 9 维特征向量。仿真路线则将预测结果映射到目标基因的 alpha、beta、gamma 和 regulation 等参数，针对每个基因，通过 ODE 求解得到 mRNA 和蛋白随时间变化的趋势。

实现层面，gene_circuit_model.py 负责动力学模型、调控网络和路径分析，modular_ai_design.py 负责元件库读取、特征编码和岭回归预测，visualization_app.py 负责页面交互、图表展示和数据导出。各模块通过明确的数据结构传递结果，既降低耦合，也便于在出现异常时判断问题来自数据输入、特征编码、模型预测还是 ODE 仿真。

图 3-1 按照数据层、特征层、预测层、仿真层和交互层展示系统总体技术路线，并补充结果校验与参数回填环节，突出程序从输入文件到可视化输出的闭环关系。程序首先读取本地 FASTA、元数据和元件库文件，经 modular_ai_design.py 完成特征构造与岭回归预测，再调用 gene_circuit_model.py 执行 ODE 仿真，最后由 visualization_app.py 在 Streamlit 界面中展示、下载并生成报告。




图 3-1 系统功能流程图

3.2 数据收集、预处理与标准化

3.2.1 原始数据采集与字段整理

字段整理时，本文尤其关注 `gene_name`、`organism` 和 `sequence_length` 三个字段。`gene_name` 用于统一同一类 gvp 成员，`organism` 用于分析来源物种和跨物种组合，`sequence_length` 用于发现异常序列和描述基因长度分布。对于后续模型而言，长度和来源本身可以继续扩展为特征；对于当前原型而言，它们主要用于数据审查和背景说明。

汇总上下文数据 `gene_metadata.csv` 的记录数只有 79 条，这与单基因元数据合计 14358 条不同。前者强调基因上下文和锚定关系，后者强调单基因序列条目。本文把二者分开描述，可以避免把锚定上下文表误解为全部元数据规模，也避免把单基因记录误认为全部都参与了同一种模型训练。

单基因元数据文件位于 `data/gene_metadata` 目录，字段包括 `accession`、`gene_name`、`protein_name`、`organism` 和 `sequence_length`。FASTA 文件位于 `data/gvp_sequences` 目录，每个文件对应一个 gvp 成员。

表 3-1 单基因元数据规模统计 (Top 10)

基因	记录数	平均长度	长度范围	字符总数
GVPI	5542	139.058	27-593	770660
GVPO	2582	124.282	26-481	320897

表 3-1 单基因元数据规模统计 (Top 10) (续)

基因	记录数	平均长度	长度范围	字符总数
GVPN	1358	337.591	242-757	458448
GVPU	1036	144.733	86-381	149943
GVPA	862	82.871	54-177	71435
GVPT	518	231.257	135-868	119791
GVPF	513	211.214	83-286	108353
GVPO	458	162.103	106-717	74243
GVPC	368	206.546	18-1026	76009
GVPL	280	296.796	226-369	83103




图 3-2 单基因元数据记录数分布

该图使用柱状图展示单基因元数据记录数靠前的 gvp 成员，用于直观表现不同基因在本地数据集中的覆盖差异。生成图表时脚本逐一读取 `data/gene_metadata` 目录下的 `gvp*_metadata.csv` 文件，统计每类基因记录数量后按降序绘制，因此图中数值与表 3-1 保持一致。

3.2.2 序列去冗余与统一命名

程序层面使用 SeqKit 工具校验序列完整性，去除冗余序列、修正序列 ID 命名规则，确保序列无碱基缺失、格式错误。并采用小写基因名作为文件名，如 `gvpa.fasta`、`gvpc.fasta` 等。论文统计将单基因元数据合计 14358 条与 `gene_metadata.csv` 的 79 条锚定上下文汇总记录区分开，避免把不同粒度的数据混为一谈。

3.2.3 标准化数据集构建与输出

参考 Swiss-Prot/TrEMBL 数据库的蛋白命名规范，建立“基因名 - 蛋白名 - 功能注释”的标准化映射表，并通过 BLASTp 比对目标基因与已注释的同源基因，验证功能一致性，成功构建本地标准化数据集，数据集共包含 17 类 gvp 单基因元数据、14358 条 FASTA 记录和 2358008 个序列字符。该数据规模足以支撑界面层的数据浏览、长度分布统计和序列碱基组成分析。

3.3 生物气囊基因线路设计

3.3.1 调控元件库建立

调控元件库位于 data/regulatory_elements 目录，共包含 promoters.csv、rbs.csv、cds.csv 和 terminators.csv 四个文件。每类元件均有 8 个候选，字段统一为 element_id、species、strength、sequence 和 description。

表 3-2 调控元件库强度统计

元件类型	数量	最小强度	平均强度	最大强度
promoter	8	0.680	0.994	1.350
rbs	8	0.720	0.996	1.280
cds	8	0.760	1.010	1.300
terminator	8	0.700	0.980	1.260




图 3-3 调控元件库强度分布

该图以散点和均值线展示启动子、RBS、CDS 和终止子四类元件的 strength 分布，便于观察元件库是否覆盖弱、中、强多个表达区间。程序通过 ModularElementLibrary 读取 data/regulatory_elements 目录中的四个 CSV 文件，并对每类元件的强度值进行可视化统计，运行过程不依赖外部数据库。

3.3.2 元件性能参数量化与组合规则建立

组合规则建立时，平台并不假设所有高强度元件叠加一定是最佳方案。启动子、RBS、CDS 和终止子分别影响不同阶段，强启动子配合强 RBS 可能提高表达，但也可能增加资源消耗。跨物种来源过多的组合可能在数值上强度较高，但在实际宿主中存在适配风险。因此程序在特征中加入物种惩罚，并在结果解释中保留平衡表达和低负荷方案。

这种规则设计与实验前筛选的目标一致。平台首先把组合空间完整列出，再用预测模型快速排序，最后通过 ODE 仿真观察典型候选的动态趋势。研究者可以根据实际目标选择高表达、平衡表达或低负荷方案，而不是只依据单一指标做决定。

四类元件各 8 个，因此单目标组合空间为 $8 \times 8 \times 8 \times 8 = 4096$ 。程序通过全组合枚举和预测评分对候选进行排序，也支持用户在界面中手工选择组合并立即进行预测与仿真。

3.3.3 调控关系与参数映射方法

调控关系在程序中由 15 个 gvp 基因节点和 15×15 调控矩阵共同表示。矩阵行对应被调控基因，列对应调控基因，正值表示激活、负值表示抑制、0 表示无直接调控；程序通过 get_gene_network 将非零矩阵元素转换为 NetworkX 边，因此参数矩阵、网络图和路径分析使用的是同一套关系数据。

参数映射以单个元件组合为输入，依次读取启动子、RBS、CDS 和终止子的 strength 值。启动子强度乘入目标基因的 alpha，表示转录起始能力变化；RBS 与 CDS 强度取平均后乘入 beta，表示翻译效率和编码序列适配性的综合影响；终止子强度用于修正 gamma，终止子越强，有效降解项越低，表达稳定性越高。

映射过程只在一次仿真任务中修改目标基因参数。simulate_design_in_circuit 会先保存原始 alpha、beta 和 gamma，完成 ODE 仿真后在 finally 语句中恢复原值，避免一次组合测试影响后续候选比较。这一设计使元件筛选、预测评分和动态仿真能够在同一界面中联动。

3.4 表达性能预测模型构建

3.4.1 特征向量构造

特征向量构造从标准化元件库开始。程序先从 promoters.csv、rbs.csv、cds.csv 和 terminators.csv 中读取候选元件，并检查 element_id、species、strength、sequence 和 description 等字段是否完整；用户随机采样得到一个组合后，程序分别根据 element_id 取回四类 ModularElement 对象。

随后提取四类元件的 strength，形成基础强度特征[promoter、RBS、CDS、terminator]；再计算启动子×RBS、CDS×终止子、启动子×CDS 三个交互项，用于表示转录、翻译和编码适配之间的协同作用。

跨物种惩罚项根据四个元件来源物种的数量计算，其计算公式为：

$$\text{species}_{\text{penalty}} = (\text{unique}_{\text{species}} - 1) \times 0.12 \#(3-1)$$

最后追加偏置项 1.0，得到 9 维特征向量。训练时每个候选组合对应一行向量，np.vstack 将多行向量堆叠为 X 矩阵，供后续岭回归使用。

3.4.2 基于岭回归的组合性能预测

组合性能预测的第一步是构造训练样本。程序通过 generate_training_set 在 4096 种理论组合空间内随机抽取样本，默认样本数为 260、随机种子为 42；每个样本先转换为 9 维特征向量，再按规则目标生成表达分数 y：基础强度和交互项提供正向贡献，跨物种惩罚提供负向贡献，并加入均值为 0、标准差为 0.05 的随机扰动，以模拟元件组合表现的不确定性。

模型训练阶段将样本按 8:2 划分为训练集和测试集。使用岭回归模型求解的目标是在最小化预测误差的同时加入 L2 正则项，得到各特征的稳定权重。本文程序中正则化系数取 0.15。

预测新组合时，predict_design_expression 先调用 build_design_features 生成同样的 9 维向量，再将其整理为 1×9 矩阵输入训练后的模型，输出组合表达分数；为了避免异常负值影响排序，程序将预测结果下限限定为 0.01。

模型效果通过训练集 R^2 、测试集 R^2 、RMSE 以及高表达分类指标共同判断。由于当前目标值来自规则生成而非真实湿实验数据，这些指标主要用于验证“元件库—特征矩阵—预测模型—候选排序”链路是否一致，为后续接入真实表达数据留下接口。

3.4.3 高表达候选筛选与排序

预测完成后，程序可对 4096 种组合全量打分。高表达候选的判定阈值采用测试集目标分数第 60 百分位数，既能保留足够候选，又能检验模型对高分区间的区分能力。

候选排序阶段不再重新训练模型，而是在四类元件各 8 个的完整组合空间中枚举 4096 种方案，对每个方案生成特征向量并计算预测分数。界面同时保留元件 ID、来源物种、预测分数、ODE 终值和目标基因等字段，便于把高表达方案、平衡方案和低负荷方案放在同一表格中比较。

3.5 可视化仿真平台开发

3.5.1 参数设置功能

参数设置功能模块集中在侧边栏。基本设置区用于选择展示基因、分子类型（mRNA 与蛋白质）、仿真起始时间和时间点数量；基因参数区通过滑动条修改选择基因的转录速率(alpha)、翻译速率(beta)和降解速率(gamma)大小；调控关系区选择调控基因、被调控基因并设置调控强度大小；模板管理区支持加载默认模板、读取已保存 JSON 模板和保存当前配置。


3.5.2 主页面功能

主页面采用八个标签页组织功能，分别为线路结构图、表达动态、参数分析、路径分析、模型验证、数据管理、报告生成和图表中心。侧边栏修改参数后，主页面各标签页会基于同一 circuit 对象重新计算或刷新，从而保证网络图、曲线、敏感性结果和导出数据之间保持一致。


结果展示按任务类型拆分。线路结构图模块提供 2D 网络、3D 网络和动态网络三种视图，节点表示 gvp 基因，边表示激活或抑制关系，并给出网络统计信息，包括节点数量、边数量以及网络密度。

表达动态模块提供折线图、面积图、散点图和雷达图，用于观察 mRNA 或蛋白随时间变化的趋势和基因间差异。其中折线图可清晰呈现单个基因在全仿真周期内的表达峰值、达峰时间和表达衰减趋势，面积图可直观对比多个基因在仿真周期内的总表达量（曲线下面积）。散点图可量化展示基因间的表达相关性（如 gvpE 与 gvpA 的表达正相关），点的分布趋势与预设的调控关系一致，可辅助验证调控矩阵的合理性。雷达图可对比多个关键时间点下不同基因的表达水平，便于快速识别基因表达的时序差异。


折线图



面积图



散点图



雷达图




图 3-4 表达动态示意图

参数分析模块支持参数敏感性分析、元数据分析、序列数据分析与组合预测。参数敏感性分析中用户可选择参数类型（alpha、beta 或 gamma）以及目标基因，程序在原值 0.5 倍到 1.5 倍之间取 10 个点，输出敏感性曲线、热力图和敏感性系数表；元数据分析给出 gen 基因元数据预览及其在不同生物体中的分布；序列数据分析给出不同 gvp 基因序列的碱基组成；组合预测部分可以选择不同的元件组合和目标基因，进行表达预测，并联动 ODE 仿真验证。

元件组合设计

启动子

P_syn_strong_01

编码序列 (CDS)

CDS_gvpA_opt_01

RBS

RBS_consensus_01

终止子

T_rrnB_01

映射到模型的目标基因

gvpA

预测并仿真当前组合

图 3-5 元件组合预测展示图

路径分析模块基于 NetworkX 搜索源基因到目标基因的简单路径，并用路径强度比较表和条形图解释直接或间接调控贡献，并给出最强调控路径。

模型验证模块支持上传包含 time 列和基因表达列的 CSV 数据，生成模型预测与实验数据对比图，并计算 RMSE 和 R^2 ；数据表均以 DataFrame 形式展示，便于排序、下载和复查。

结果保存与导出功能分布在数据管理、报告生成和图表中心三个模块。数据管理模块提供仿真结果 CSV、网络结构 JSON、模型参数 JSON 和用户上传数据预览；报告生成模块允许选择报告内容，包含线路结构、表达动态、参数分析、路径分析和模型验证等模块，并输出 Markdown 或 HTML 报告。图表中心模块与数据管理共同服务于论文图表整理：前者集中展示元数据统计、元件组合界面和网络统计等截图，后者保留可复核的原始表格和参数文件，使图形结论能够回溯到具体数据来源。

3.6 参数调优与模型校准

3.6.1 参数范围设定与调优策略设计

参数范围设定分为预测参数、动力学仿真参数和实验校准参数三类。预测参数主要包括训练样本数、随机种子、岭回归正则化系数和高表达阈值，用于控制评分模型的泛化能力；仿真参数包括起止时间、时间点数、 α 、 β 、 γ 以及调控边权重，用于控制 ODE 响应；校准参数则在实验数据上传后由用户选择 α 、 β 、 γ 中的一类或多类，并进入差分进化搜索。这样的分层设置可以把“组合评分”“动态解释”和“实验拟合”三个目标分开处理，避免把所有误差都归因于某一个参数。

在具体范围上，界面中 α 、 β 通常按 0~2 的滑块调节， γ 按 0~1 调节；敏感性分析采用一次只扰动一个参数的方法，在当前值 0.5~1.5 倍之间取 10 个等距点。评价响应不只看终值，还同时关注峰值、达峰时间和曲线下面积。终值用于判断最终表达水平，峰值和达峰时间用于识别瞬态过冲，AUC 则反映整个时间窗内的累积表达量。若某参数轻微变化就造成终值或 AUC 大幅波动，该参数在后续设计中需要优先保守设置。

3.6.2 正则化系数、筛选阈值与仿真参数调优

预测模型调优以正则化系数、训练样本数和高表达阈值为核心。程序由元件强度构造 9 维特征向量，训练目标由元件强度规则加入少量随机扰动生成。本文采用 260 个样本、42 号随机种子和 8:2 划分，相当于约 208 个训练样本与

52 个测试样本。岭回归正则化系数设为 $\alpha=0.15$ ，一方面可以抑制交互特征导致的系数放大，另一方面不会过度压低强元素组合的表达差异。

高表达阈值采用测试集目标分数第 60 百分位，而不是固定绝对值。其原因是当前训练目标仍属于规则生成数据，绝对表达量尚未与真实蛋白浓度或超声信号对齐；使用分位数可以把问题转化为候选排序和高分区间识别，更符合湿实验前筛选场景。回归侧用训练集 R^2 、测试集 R^2 和 RMSE 判断连续评分是否稳定，分类侧用准确率、召回率和 F1 判断高表达候选是否被漏筛；当测试 R^2 接近训练 R^2 且 F1 没有明显下降时，说明参数设置没有出现明显过拟合。




图 3-6 参数调优与模型校准关键设置统计图

图 3-6 展示出样本规模、敏感性取点、校准迭代和参数扰动边界等可量化信息。可以看出，本研究的调优策略并不是单纯增加迭代次数，而是先用固定随机种子和 8:2 划分稳定预测模型，再用局部扰动观察 ODE 响应，最后在实验数据约束下扩大到 0.5~2.0 倍的校准搜索区间。该顺序使模型筛选、动力学解释和实验拟合之间形成递进关系。

模型校准在存在实验数据时启动。上传 CSV 必须包含 time 列和至少一个基因表达列，程序以 time 列的最小值和最大值作为仿真时间窗，并在相同时间点输出蛋白预测值。适配度计算以各可匹配基因的 MSE 均值为目标，同时用实验数据总方差折算 R^2 作为辅助指标。这样处理可以让不同基因列共同约束参数，而不是只让单一曲线决定校准方向。

校准算法采用差分进化，在所选参数类型范围内对所有基因的对应参数同时搜索。每个参数的上下界为当前值的 0.5~2.0 倍，默认迭代 100 次，界面允

许在 10~500 次之间调整。差分进化适合这类非线性 ODE 拟合问题，因为它不要求目标函数可导，也能在多个参数存在耦合时进行全局搜索。校准完成后，程序保留校准前参数并重新仿真，输出校准前后 RMSE、曲线对比和实验散点，从而判断误差下降是否来自整体趋势改善，而不是某个时间点的偶然贴合。

3.6.3 最优参数组合确定与依据说明

最优参数组合的确定采用“先稳定、再解释、后筛选”的顺序。首先比较训练集和测试集 R^2 、RMSE 以及高表达分类 F1，排除只在训练样本上表现好的设置；其次查看敏感性曲线和敏感性系数，确认输出不会被单个 α 、 β 或 γ 的微小扰动异常放大；最后结合预测分数、ODE 终值、峰值/AUC 和调控路径强度，对候选组合进行综合排序。

因此，本文在实验结果中同时报告平台枚举最优、传统手工平衡、随机筛选最优、平衡候选和低负荷保守方案。若某方案预测分数最高但敏感性过强、校准后参数贴近边界或跨物种惩罚较大，则只将其视为高表达候选；若方案输出略低但路径解释清晰、参数扰动后稳定、校准前后曲线趋势一致，则更适合进入后续实验验证。这样的判定逻辑可以避免单纯追求最大表达分数造成宿主负担或数值不稳定。

校准后的参数不直接替代生物学结论，而是作为缩小搜索范围和形成实验假设的依据。最终方案需要同时满足预测分数较高、ODE 动态无异常爆炸、关键路径方向符合调控逻辑、RMSE 下降或 R^2 提升、参数未普遍压在上下边界以及导出的参数文件可复现这几个条件。若真实实验数据量较少，校准结果应作为探索性参考；待多批次数据加入后，再通过交叉验证或留出实验组合检验其泛化能力。

第四章 实验结果分析

4.1 实验环境与数据基础

4.1.1 验证环境说明

验证在本地离线环境中完成，程序依赖 NumPy、SciPy、Matplotlib、NetworkX、Streamlit、Pandas、Plotly 和 Biopython。由于所有输入文件均为本地文件，结果不会受到在线数据库更新的影响。

4.1.2 数据规模与元件库统计

从数据规模看，GVPJ、GVPO 和 GVPN 的记录数较多，GVPE 和 GVPI 的记录数较少，说明数据集存在明显覆盖差异。该差异会影响未来真实监督模型的训练，因为模型可能更容易学习高覆盖基因的规律，而对低覆盖基因泛化不足。当前原型使用规则生成训练目标，暂时降低了这种不平衡的影响，但在后续接入实测数据时仍需要采用分层采样或类别权重等方法处理。

从元件库看，四类元件的平均强度都接近 1，说明元件库的设计覆盖了弱、中、强多个区间，而不是单一高强度集合。这样的强度分布有利于比较高表达与低负荷之间的差异，也有利于生成平衡候选。若元件库只有强元件，平台很难给出低负担方案；若只有弱元件，则很难观察到表达增强效果。

程序统计显示，单基因元数据合计 14358 条，FASTA 记录同为 14358 条，序列字符总数为 2358008。调控元件库共 32 个元件，构成 4096 种元件组合。

4.2 整体性能分析

4.2.1 最优参数组合与整体预测结果

模型整体表现较好，与训练目标的构造方式有关。目标分数由元件强度和交互项产生，而预测模型使用的特征正是这些变量，因此 R^2 较高是合理结果。该结果证明的是程序链路和规则目标一致，而不是证明真实细胞中表达一定达到相同水平。本文在结果解释中始终保留这一边界，避免过度外推。

尽管如此，该指标仍然有工程意义。若模型在规则生成数据上都无法得到稳定拟合，说明特征构造、训练划分或预测流程可能存在问题；当前结果表明，

至少在原型设定下，元件库读取、特征生成、模型训练和预测输出之间是协调的，可以支撑后续可视化和候选排序分析。

表 4-1 表达预测模型整体评价指标

指标	数值	含义
训练样本数	260	界面默认训练规模
训练集 R^2	0.978	训练拟合解释度
测试集 R^2	0.970	测试泛化解释度
RMSE	0.053	连续表达分数误差
准确率	0.923	高表达阈值判别一致性
F1 分数	0.905	高表达候选筛选质量




图 4-1 测试集预测拟合结果

该图采用真实目标分数与预测分数的散点对比形式，并加入对角参考线，用于判断岭回归模型在测试集上的拟合偏差。图中数据来自 `train_predictor_from_library` 函数在 260 个规则生成样本、42 号随机种子和 8:2 划分条件下的测试集输出， R^2 和 RMSE 由同一批预测值计算得到。

4.2.2 平台运行效率与资源占用情况

系统没有调用外部模型服务，核心计算由本地 Python 完成。岭回归训练、4096 组合评分和 ODE 仿真均可在普通桌面环境中完成；LSODA 缓存机制减少了参数不变时的重复 ODE 求解。

4.3 模型评价指标分析

4.3.1 回归拟合效果分析

测试集 R^2 为 0.970，RMSE 为 0.053，说明模型对规则生成目标具有较强解释能力。训练集 R^2 与测试集 R^2 差距较小，未出现明显过拟合。

4.3.2 高表达分类准确性分析

以测试集第 60 百分位数 2.733 作为高表达阈值时，准确率为 0.923，精确率和召回率均为 0.905，F1 分数为 0.905。该结果说明模型能较稳定地区分高分候选。

4.3.3 RMSE、 R^2 、准确率与 F1 分数解释

在本研究中， R^2 和 RMSE 主要用于连续评分层面，准确率和 F1 主要用于候选筛选层面。若只看 R^2 ，可能忽略高表达候选是否被正确筛出；若只看准确率，可能忽略分数排序是否合理。特别是在后续真实实验中，高表达候选通常比低表达样本更有实验价值，因此 F1 分数能够更好地反映筛选质量。

指标解释还必须和阈值定义绑定。本文采用测试集第 60 百分位数作为高表达阈值，是为了让正负样本比例相对均衡，便于观察分类质量。如果未来实验希望只选择最强的 10% 候选，阈值应相应提高，准确率和 F1 也会发生变化。因此平台保留阈值可调整空间是必要的。

R^2 反映排序和整体解释度，RMSE 反映分数误差，准确率与 F1 反映高表达候选筛选效果。四类指标共同使用，可以避免只依赖单个指标而造成误判。

4.4 典型组合案例分析

4.4.1 高表达组合仿真结果

全组合枚举最优方案为 P_strong / RBS_consensus / CDS_opt / T_mB，预测分数为 3.797， $\log_{10}(\text{gvpA 蛋白终值})$ 为 27.275。该方案采用了强启动子、高一

致性 RBS 和密码子优化的 CDS，在模型中呈现出短期超高表达的特征，是快速提升气囊合成量的首选组合。但需要注意的是，该方案的高元件强度组合会带来较高的表达敏感性，因此在实际应用中需要评估其调控难度与稳定性风险。

4.4.2 平衡表达组合仿真结果

平衡候选方案为 P_{oxy_resp} / RBS_{high} / CDS_{gvpE} / T_{gc}，预测分数为 2.669，但 log10 终值达到 25.583。可以看到，该方案的预测分数并非最高，但其仿真终值仍处于较高水平，说明元件强度组合和 ODE 映射之间存在非线性放大效应，即中等强度的元件搭配也能实现较高的表达输出，同时避免了高表达方案的极端代谢压力。

4.4.3 低负荷组合仿真结果

低负荷保守方案为 P_{stress} / RBS_{safe} / CDS_{safe} / T_{low}，预测分数为 2.206，log10 终值为 23.293。该方案不追求最高输出，更适合在宿主负担和稳定性优先的场景中作为候选。

4.5 消融实验

4.5.1 不同元件特征对预测结果的影响

表 4-2 分组消融实验结果

模型设置	测试集 R ²	RMSE	准确率	F1 分数	ΔR^2
完整模型	0.970	0.053	0.923	0.905	0.000
去除启动子相关	0.559	0.207	0.712	0.595	-0.412
去除 RBS 相关	0.499	0.220	0.750	0.711	-0.471
去除 CDS 相关	0.816	0.133	0.808	0.783	-0.154
去除终止子相关	0.828	0.129	0.827	0.791	-0.142
去除全部交互项	0.965	0.058	0.923	0.905	-0.005
去除物种兼容惩罚	0.956	0.065	0.885	0.857	-0.014

消融结果表明，去除启动子相关特征和 RBS 相关特征后 R²下降最明显，说明转录起始与翻译起始仍是当前规则目标中最关键的贡献来源。去除交互项影响较小，是因为直接强度特征仍能解释大部分规则目标。

4.5.2 关键特征贡献分析

消融实验还说明，交互项的影响虽然小于基础强度，但不能简单删除。交互项反映的是“组合效应”，当基础强度相近时，交互项可能成为区分候选的重要依据。物种兼容惩罚的作用也类似，它对整体 R^2 影响有限，却会影响高表达候选边界，说明它更像是风险校正因子，而不是主导表达强度的因子。

CDS 和终止子相关特征的下降幅度居中，说明编码效率与转录终止稳定性对表达评分有补充贡献。物种兼容惩罚影响不如启动子和 RBS 显著，但其删除会降低高表达筛选 F1，说明兼容性信息对候选边界有修正作用。

4.6 对比实验

本节将平台全枚举、传统手工平衡、随机筛选、平衡候选和低负荷保守五类方案放在同一评价口径下比较，指标包括预测分数、 $\log_{10}(\text{gvpA 蛋白终值})$ 和相对传统方案倍数。表 4-3 给出数值结果，图 4-2 展示预测评分与动态输出之间的差异。

表 4-3 不同设计策略对比结果

方案	选择方式	预测分数	$\log_{10}$ 终值	相对传统方案倍数
平台全枚举 最优	4096 种组合全枚举排序	3.797	27.275	235.971
传统手工平 衡	中等强度元件经验组合	2.682	24.902	1.000
随机筛选	随机抽取 50 种组合后取最 高分	3.193	25.494	3.913
平衡候选	中高分区间约束筛选	2.669	25.583	4.799
低负荷保守	优先选择低负担元件	2.206	23.293	0.025




图 4-2 不同设计策略预测分数与 ODE 输出对比

该图采用双指标柱状图，同时展示不同设计策略的预测分数和 $\log_{10}$ 形式的 gvpA 蛋白仿真终值，便于观察“预测评分”和“动态输出”之间的差别。程序先对 4096 种元件组合进行全枚举评分，再选择平台最优、传统平衡、随机筛选、平衡候选和低负荷方案调用 `simulate_design_in_circuit` 执行 ODE 仿真。

4.6.1 平台枚举最优方案与传统手工方案对比

平台枚举最优方案的预测分数比传统手工平衡方案更高，ODE 输出相对传统方案约 236 倍。由于 ODE 模型未加入饱和与资源限制，该倍数应理解为趋势放大，而不是湿实验浓度倍数。

4.6.2 随机筛选方案与约束筛选方案对比


随机抽取 50 种组合得到的最优方案预测分数为 3.193，低于全枚举最优方案。说明在 4096 种组合空间中，仅靠随机筛选存在错过全局高分组合的风险。


4.6.3 不同设计策略的适用场景分析

全平台枚举最优方案（高表达方案）适合快速增强信号，例如体内超声分子成像、深部组织细胞示踪等场景。平衡方案兼顾了表达水平和系统稳定性，更适合长期工程菌定植、氧气响应型动态调控、以及需要持续稳定成像的活体监测场景。低负荷方案则适合应用在益生菌改造、环境工程菌投放等对宿主生长状态要求较高的场景。平台的价值不是强制选择最高分，而是同时呈现多种


4.7.1 调控网络结构展示效果

程序构建的 GV 调控网络包含 15 个节点、26 条边，其中 25 条为激活边，1 条为抑制边，网络密度为 0.124。该网络能够在 2D、3D 和动态网络视图中展示。其中 2D 网络为静态平面展示；3D 网络为立体展示，支持旋转和缩放；动态网络可通过选择不同时间点动态展示基因表达随时间的变化。





动态基因调控网络（时间点：8/20, $t=18.4$ ）



4.7.2 动态仿真曲线展示

动态仿真曲线展示对应第 3.5.2 节中的表达动态模块。用户在侧边栏确定展示基因、分子类型和时间点数量后，平台调用 ODE 求解器生成 mRNA 与蛋白

质时间序列，并在折线图、面积图、散点图和雷达图中复用同一结果表。这样可以保证峰值、达峰时间、曲线下面积和基因间相关性来自同一次仿真，避免不同图表之间出现数据口径不一致。图用于比较高表达、平衡表达和低负荷方案下 *gvpA* 的表达动态。高表达方案的终值和曲线下面积更大，适合快速增强信号；平衡方案曲线上升相对平稳，适合持续监测；低负荷方案输出较低，但对宿主负担和参数扰动更保守。该结果与第 4.6 节不同设计策略的比较结论一致，也对应第 3.5 节中表达动态模块用于观察峰值、达峰时间和衰减趋势的设计目标。




图 4-6 *gvpA* 表达动态对比图

4.7.3 参数分析与数据管理展示效果

本节综合验证第 3.5.2 节中参数分析、路径分析、模型验证、数据管理、报告生成和图表中心等标签页。先通过单参数扰动判断 ODE 输出稳定性，再用路径强度解释调控关系，随后展示元件组合预测和元数据统计，最后检查仿真结果、网络结构与模型参数能否以表格或文件形式复核导出。




图 4-7 gvpA 转录速率敏感性分析

图 4-7 由敏感性曲线和热力图组成，重点展示 gvpA 转录速率 α 变化时多个核心基因终值的响应方向和变化幅度。程序将 $\alpha(\text{gvpA})$ 在原值 0.5 倍到 1.5 倍之间取 10 个点，每次修改参数后重新运行 ODE 仿真，随后恢复原始参数并绘制 $\log_{10}$ 终值矩阵。

表 4-4 gvpE 到 gvpA 调控路径强度

路径	长度	强度
$\text{gvpE} \rightarrow \text{gvpA}$	1	0.300
$\text{gvpE} \rightarrow \text{gvpC} \rightarrow \text{gvpA}$	2	0.040
$\text{gvpE} \rightarrow \text{gvpB} \rightarrow \text{gvpA}$	2	0.030
$\text{gvpE} \rightarrow \text{gvpC} \rightarrow \text{gvpB} \rightarrow \text{gvpA}$	3	0.003




图 4-8 gvpE 到 gvpA 调控路径强度

表 4-4 和图 4-8 把 *gvpE* 到 *gvpA* 的直接和间接调控路径转化为可比较的数值结果，路径强度采用沿途调控边权重乘积表示。程序通过 `find_regulatory_paths` 查找最大长度为 3 的简单路径，再调用 `calculate_path_strength` 逐条计算强度，并对去重后的路径结果排序绘图。该结果与 4.7.1 中网络结构展示的路径关系相互印证，使用户不仅能看到连接关系，也能比较不同路径对目标基因的相对贡献。




图 4-9 Promoter-RBS 预测表达热力图

图 4-9 从启动子和 RBS 组合角度展示表达强度差异，对应第 3.5.2 节参数分析模块中的组合预测功能。当前程序通过选择启动子、RBS、CDS 和终止子构造特征向量，热力图可视为固定 CDS 和终止子条件下对 Promoter-RBS 组合评分结果的二维展示。该图强调调控元件之间存在组合效应，不能只按单个元件强度进行简单排序。




图 4-10 Gvp 元数据规模统计图

图 4-10 展示不同 Gvp 成员的数据规模差异，与表 3-1 和图 3-2 共同说明本地数据集存在基因类别覆盖不均衡的问题。该图对应参数分析模块中的元数据分析功能：程序基于 data/gene_metadata 目录中的单基因元数据文件，按文件统计记录数、平均长度和长度范围，再将记录数用于图形展示，为后续真实数据接入时的采样与校准提供依据。



图 4-11 线路结构图界面

图 4-11 展示平台在线路结构图模块中的前端效果，体现用户能够通过界面查看生物气囊基因调控网络，而不需要直接阅读矩阵参数。用户进入“线路结

构图”标签页后，可在 2D 可视化、3D 可视化和动态网络之间切换，界面自动调用 `get_gene_network` 生成节点和边。



图 4-12 网络统计信息界面

图 4-12 展示网络统计信息区，用指标卡形式概括节点数量、边数量和网络密度，Streamlit 运行时根据 NetworkX 图对象实时计算统计值，并通过 `st.metric` 组件显示；当侧边栏调整调控矩阵或边权参数后，网络结构和统计指标会随之更新，保证参数设置与主页面展示保持联动。



图 4-13 元件组合设计界面




图 4-14 gvp 基因仿真轨迹图

图 4-13 展示 AI 组合预测模块的交互入口，用户可以选择启动子、RBS、CDS 和终止子，并指定映射到 ODE 模型的目标基因。运行时界面先通过 ModularElementLibrary 加载四类元件选项，用户点击预测后调用岭回归模型输出表达分数，并进一步调用 ODE 仿真显示目标基因轨迹，如图 4-14 展示 gvpA 在当前元件组合下的仿真轨迹。



图 4-15 数据管理界面

图 4-15 展示系统的数据管理界面，支持仿真结果、网络结构、模型参数下载与用户上传功能。用户在“数据管理”标签页选择下载类型后，系统根据仿真结果生成对应的 CSV 文件，根据网络结构与模型参数生成对应的 JSON 文件，同时提供数据预览功能，用表格形式呈现仿真结果、元数据或上传数据，便于用户复核图表背后的原始数值。

第五章 结论与展望

5.1 实验结论

总体来看，本文完成了面向生物气囊基因线路的计算原型：以本地 FASTA、元数据和调控元件库为输入，建立从元件组合、表达评分、ODE 仿真到可视化展示和结果导出的流程。岭回归预测器在规则生成数据上取得测试集 R^2 为 0.970、RMSE 为 0.053 的结果，说明当前特征能够表达元件强度规则；4096 种组合枚举也使候选筛选从经验判断转向可追溯排序。平台层面，线路编辑、网络展示、表达曲线、参数敏感性、路径分析和数据导出被整合在同一界面中，便于课程论文、原型验证和湿实验前的方案比较。需要强调的是，这些结果证明的是程序链路完整和相对趋势可比较，真实表达量与超声信号仍需后续实验数据进一步校准。

5.2 现存不足

当前训练目标由程序规则生成，还没有接入真实表达量、蛋白定量或超声回波数据。因此指标只能证明平台内部链路稳定，不能替代实验验证。

ODE 模型描述了转录、翻译、降解和调控，但尚未引入蛋白折叠、气囊装配、宿主代谢负担、资源竞争和气囊塌陷压力等机制。后续应增加饱和项和资源约束，降低长时间窗下数值发散的问题。

当前预测输出为单一分数，没有给出置信区间。未来可采用交叉验证、Bootstrap 或贝叶斯回归估计不确定性，使候选排序不仅有均值，也有风险范围。

5.3 未来展望

在实验闭环方向上，未来平台应支持把真实测量结果回填到模型中。实验人员完成若干候选组合的表达测定后，可以将结果上传到模型验证模块，系统计算拟合误差并校准 α 、 β 和 γ 等参数。经过多轮迭代，平台就能从规则驱动原型逐步转向数据驱动工具。

在多目标优化方向上，可以把表达强度、宿主负担、装配稳定性和不确定性同时作为目标。平台可用帕累托前沿展示不同目标之间的折中关系，让研究者根据具体应用选择方案。例如成像增强场景更重视信号强度，长期定植场景

更重视低负担和稳定性。多目标视角会使气囊基因线路设计更接近真实工程决策。

未来工作可从三方面推进：数据上接入真实异源表达和超声信号数据；模型上加入蛋白语言模型嵌入、多目标优化和不确定性评估；平台上增加 SBML 导出、版本化设计记录和在线部署。这样可以将当前原型发展为面向生物气囊线路设计的实验闭环辅助系统。

参考文献

- [1] 丁晴, 林海天, 盛琦, 等. 谷氨酸棒杆菌 ATCC13032 基因组中性位点的计算机筛选及表征[J/OL]. 微生物学报, 1-16[2026-05-17].
- [2] 肖婷元, 邓鑫月, 万喆, 等. 新型融合蛋白的设计、构建及其高效生物合成策略[J]. 现代肿瘤医学, 2026, 34(01): 112-118.
- [3] 汪君仪, 钟皓森, 方志超, 等. 微生物基因组设计合成进展[J]. 中国科学:生命科学, 2025, 55(10): 1979-1988.
- [4] 孙小松, 张帆, 王峥. 基于 pCAMBIA1304-CYP3A4 的工程藻株模型构建及其对赤潮毒素的生物修复机制研究[J]. 生态与资源, 2025, (07): 46-50.
- [5] 徐胜超. 基于关键字树的生物基因多序列比对并行计算方法[J]. 计算机与数字工程, 2025, 53(07): 1789-1793.
- [6] 杨梦霞, 刘峻豪, 陈腾飞, 等. 基于生物信息学数据筛选脓毒症生物标志物[J]. 现代生物医学进展, 2025, 25(13): 2110-2117.
- [7] 郭嵩然, 乔连生, 褚辉程, 等. 基于计算机辅助水解的薏苡肽类血管紧张素 II 1 型受体拮抗活性预测及功能评价[J]. 中南药学, 2025, 23(06): 1547-1554.
- [8] 官未然, 王平. 圆锥角膜遗传因素及生物力学的研究进展[J]. 医师在线, 2025, 15(06): 86-90.
- [9] 刘沛昕, 潘敏青, 刘砾雯, 等. AI 赋能生物医药的创新探索与挑战[J]. 现代医院, 2025, 25(04): 607-612.
- [10] 龚钰翔, 龙欢, 黄开耀. pH 对生物合成超声分子影像探针气囊充放气的调控[J]. 生物工程学报, 2023, 39(10): 4308-4321.
- [11] 黄驰, 张月, 辛莹, 等. 基于生物合成气囊的影像造影剂的研究进展[J]. 临床超声医学杂志, 2021, 23(08): 608-610.
- [12] Ghosh J, Alshahrani M A, Palodhi A, et al. Identification and therapeutic investigation of biomarker genes underpinning hepatocellular carcinoma: an in silico study utilising molecular docking and dynamics simulation[J]. Frontiers in bioinformatics, 2025, 5: 1567748.
- [13] Kumar H, Vijayakumar S, Shintre N, et al. In silico exploration of biosynthetic gene clusters in marine Streptomyces sp. and Nocardiopsis sp. from the western coast of India: Genome-based profiling using whole genome sequencing[J]. Journal of Genetic Engineering and Biotechnology, 2025, 23(2): 100483.

- [14] Matthay P ,Schalck T ,Simoens K , et al. In silico identification of gene targets to enhance C12 fatty acid production in Escherichia coli.[J]. Applied microbiology and biotechnology, 2025, 109(1): 116.
- [15] Das P R ,Pradhan K A . Unveiling key hub genes in E. coli biofilm formation: An in silico approach integrating differential gene expression, biosurfactant targeting, MD simulation and MM-PBSA free energy calculations.[J]. Computational biology and chemistry, 2025, 119: 108596.
- [16] Sheervalilou M ,Ghanei M ,Arabfard M . Shared blood gene signature in lung adenocarcinoma and microbial lung infections: a bioinformatic analysis and in silico validation[J]. Discover Oncology, 2025, 16(1): 1403.

致 谢

在本论文的撰写与系统开发过程中，首先要由衷感谢我的指导教师。感谢老师在选题方向、文档结构以及技术路线方面给予的悉心指导，您严谨的治学态度令我受益匪浅。

同时也向我的父母致以最深的谢意。感谢你们多年来在生活上的默默支持与精神上的无条件信任，是你们的鼓励让我能够专注学业，顺利完成研究。