

天津大学

本科生毕业论文



题目：基于生物大模型的气囊蛋白元件识别研究

学 院 智能与计算

专 业 人工智能

年 级 2022 级

姓 名 戴博林

学 号 3022244250

指导教师 宫秀军

独创性声明

本人声明：所呈交的毕业设计（论文），是本人在指导教师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本毕业设计（论文）中不包含任何他人已经发表或撰写过的研究成果。对本毕业设计（论文）所涉及的研究工作做出贡献的其他个人和集体，均已在论文中作了明确的说明。本毕业设计（论文）原创性声明的法律责任由本人承担。

论文作者签名：

戴博林

2026 年 5 月 15 日

本人声明：本毕业设计（论文）是本人指导学生完成的研究成果，已经审阅过论文的全部内容。

论文指导教师签名：

官秀军

2026 年 5 月 15 日

摘要

气囊蛋白广泛存在于蓝细菌、部分细菌和古菌中，是微生物浮力调节和气囊结构维持的重要蛋白组分。随着气囊结构在超声成像、声学报告基因和蛋白工程中的应用价值不断提高，从多物种气囊蛋白序列中识别潜在功能区域具有重要意义。然而，气囊蛋白功能区域通常表现为局部片段、重复区域或蛋白互作相关区域，且不同来源序列存在低同源性、标注不足和候选边界不清等问题，使得仅依赖全长序列或单一证据难以准确识别候选功能区域。基于此，本文以 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 八类气囊蛋白为研究对象，构建片段级候选功能元件识别流程。

本文首先对多来源气囊蛋白序列进行合并、去冗余、异常序列过滤和结构化整理。考虑到潜在功能元件多位于蛋白局部区域，本文采用滑动窗口方法构建片段级分析对象。针对低同源性和标注不足导致传统序列特征表达能力有限的问题，本文采用蛋白质语言模型 Evolutionary Scale Modeling 2 提取片段嵌入表示，以表征局部序列的上下文关系、进化约束和潜在结构功能信息。在此基础上，利用均匀流形近似与投影方法对高维嵌入进行低维映射，并结合层次密度聚类算法 H DBSCAN 完成候选片段初筛。

由于模型嵌入和聚类结果不能直接等同于生物学功能结论，本文进一步结合多源证据对候选区域进行评价。序列层面，采用快速傅里叶变换多序列比对工具计算候选片段保守性；结构层面，结合基于蛋白语言模型的结构预测工具 ESMFold 和 PyMOL 分子结构可视化系统，分析候选区域的预测结构位置和二级结构特征。最终，本文筛选得到 29 个优先候选功能区域。其中，GvpA 的 25 - 55 位点区域和 16 - 46 位点区域与壳体骨架装配相关区域在序列位置上具有一定对应关系；GvpC 的 76 - 111 位点区域和 102 - 137 位点区域与重复片段、外表面稳定作用及抗塌陷调控相关区域在位置和结构特征上较为接近。

综上，本文构建的“片段划分—语言模型嵌入—降维聚类初筛—多源证据验证”流程能够较系统地筛选气囊蛋白候选功能区域，可为后续突变实验、功能验证和气囊蛋白工程改造提供候选对象参考。

关键词：气囊蛋白，蛋白质语言模型，候选功能元件，均匀流形近似与投影，层次密度聚类，多序列比对，结构预测

ABSTRACT

Gas vesicle proteins are widely found in cyanobacteria, some bacteria, and archaea, and are important for microbial buoyancy regulation and gas vesicle structural maintenance. With their growing value in ultrasound imaging, acoustic reporter genes, and protein engineering, identifying potential functional regions from multi-species sequences is important. However, these regions are often local fragments, repeat regions, or protein interaction-related regions, and available sequences show low homology, insufficient annotation, and unclear boundaries. Therefore, full-length sequence analysis or single-source evidence is insufficient. This study focuses on GvpA, GvpC, GvpG, GvpJ, GvpK, GvpN, GvpO, and GvpP, and constructs a fragment-level workflow.

Multi-source sequences were merged, deduplicated, filtered, and organized. Since functional elements are mostly local regions, sliding windows were used to generate fragments. To better represent low-homology and poorly annotated fragments, the Evolutionary Scale Modeling version 2 protein language model was used to extract embeddings. Uniform Manifold Approximation and Projection and HDBSCAN were then used for dimensionality reduction and candidate screening.

Because embedding-based clustering cannot directly prove biological function, conservation and structural evidence were further integrated. Multiple Alignment using Fast Fourier Transform was used for conservation analysis, while ESMFold and PyMOL Molecular Graphics System were used for structural analysis. Finally, 29 prioritized candidate functional regions were identified. The GvpA 25–55 and 16–46 regions corresponded to shell scaffold assembly-related regions, while the GvpC 76–111 and 102–137 regions were close to repeat fragments and regions related to external surface stabilization and collapse resistance.

In summary, the proposed fragment-level multi-evidence workflow can provide candidate references for subsequent mutagenesis, functional validation, and protein engineering.

KEY WORDS: Gas Vesicle Protein ; Protein Language Model ; Candidate Functional Element; Uniform Manifold Approximation and Projection; HDBSCAN; Multiple Alignment using Fast Fourier Transform; ESMFold

目 录

第一章 绪论	1
1.1 研究背景	1
1.1.1 气囊蛋白的研究背景	1
1.1.2 气囊蛋白的应用价值	1
1.2 研究目的与意义	2
1.2.1 研究目的	2
1.2.2 理论意义	2
1.2.3 应用意义	3
1.3 国内外研究现状	3
1.3.1 实验结构与功能研究现状	3
1.3.2 传统生物信息学方法研究现状	4
1.3.3 深度学习结构预测方法研究现状	4
1.3.4 蛋白质大语言模型研究现状	5
1.4 现有研究存在的问题	5
1.4.1 功能元件边界缺乏统一判定标准	5
1.4.2 单一预测方法可靠性有限	6
1.5 本文主要研究内容与贡献	6
1.6 论文组织结构	7
第二章 理论基础与关键技术	8
2.1 气囊蛋白及候选功能元件基础	8
2.1.1 主要 GVP 蛋白类型及功能	8
2.1.2 气囊蛋白候选功能元件的概念	8
2.2 蛋白序列与功能区域识别理论	9
2.2.1 蛋白序列与结构功能关系	9
2.2.2 序列保守性与功能重要性的关系	9
2.3 蛋白语言模型与片段级表示基础	9
2.3.1 蛋白语言模型的基本原理	9

2.3.2 片段级表示用于功能元件识别的依据	10
2.4 关键技术原理	10
2.4.1 ESM-2 嵌入表示原理	10
2.4.2 UMAP 降维原理	11
2.4.3 HDBSCAN 聚类原理	11
2.4.4 MSA 保守性分析原理	12
2.4.5 ESMFold 结构预测原理	13
2.5 实验环境与技术实现基础	13
第三章 研究方法	14
3.1 方法设计动机	14
3.2 研究流程总体设计	15
3.3 数据预处理	15
3.3.1 数据来源与研究对象	16
3.3.2 序列合并与去冗余	16
3.3.3 数据清洗与 JSON 字段组织	16
3.4 蛋白片段级嵌入提取方法	17
3.4.1 蛋白语言模型选择	17
3.4.2 滑动窗口片段构建	17
3.4.3 片段嵌入提取与归一化	18
3.5 降维聚类与候选片段初筛方法	18
3.5.1 UMAP 与 HDBSCAN 参数设置	18
3.5.2 聚类结果评价方法	19
3.5.3 位置稳定性与跨物种覆盖分析	20
3.5.4 近距离候选片段后处理	20
3.6 候选片段多维度验证方法	21
3.6.1 ESM-2 注意力分数分析	21
3.6.2 MAFFT 多序列比对与保守性评分	23
3.6.3 ESMFold 结构预测方法	24
3.6.4 PyMOL 二级结构统计与结构评分	24
3.7 结果整合与数据库构建方法	26
3.7.1 多源结果整合方法	26

3.7.2 SQLite 单表数据库设计	26
3.8 参数设置与参数敏感性分析	27
第四章 实验结果与分析	29
4.1 数据集构建	29
4.2 片段聚类结果分析	30
4.2.1 片段生成与 ESM-2 嵌入结果	30
4.2.2 UMAP 降维可视化结果	30
4.2.3 HDBSCAN 聚类结果	32
4.2.4 聚类质量评价结果	34
4.3 位置稳定性与跨物种覆盖综合分析	35
4.3.1 综合统计结果	35
4.3.2 三种 ESM-2 模型结果对比实验	37
4.4 多维度验证结果分析	38
4.4.1 ESM-2 注意力分数验证结果	38
4.4.2 MAFFT 多序列比对保守性分析结果	40
4.4.3 ESMFold 结构预测与 PyMOL 二级结构分析结果	42
4.4.4 多维度验证结果综合分析	44
4.5 数据库原型展示结果	48
4.5.1 数据库表结构和存储结果	48
4.5.2 Streamlit 界面展示结果	50
第五章 结论与展望	52
5.1 研究结论	52
5.2 不足与展望	52
参考文献	54
附 录	57
致 谢	58

第一章 绪论

1.1 研究背景

1.1.1 气囊蛋白的研究背景

气囊是一类广泛存在于蓝细菌、部分细菌和古菌中的胞内中空蛋白纳米结构，主要功能是帮助微生物调节浮力，使其在水体或高盐环境中改变垂直分布位置，从而获得适宜的光照、氧气、营养盐和盐度条件^[1-2]。与脂质膜包裹的细胞器不同，气囊不含脂质膜，而是由蛋白质壳层围成气体空间，能够在允许气体扩散的同时阻止液态水进入，并在一定外界压力下维持结构稳定^[1]。

气囊的形成依赖一组气囊蛋白基因，即 *gvp* 基因。不同微生物中的 *gvp* 基因簇在组成和排列方式上存在差异，但通常包括主要结构蛋白、外部稳定蛋白和装配辅助蛋白等^[2-3]。其中，GvpA 通常被认为是构成气囊壳体的主要结构蛋白，具有较高保守性和较强疏水性，能够参与气囊壁层的有序排列^[1-2,4]；GvpC 多位于气囊外表面，能够增强气囊壳体的机械稳定性，提高气囊抵抗外界压力的能力^[5-6]。此外，GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 等蛋白也可能参与气囊形成、装配调控和结构维持过程^[5,7-8]。近期研究还发现，部分 GVP 蛋白之间的相互作用和相分离行为可能影响气囊装配与聚集状态^[8-9]。

气囊蛋白研究有助于理解微生物浮力调节和环境适应机制，也可为蛋白质自组装研究提供模型。气囊结构由多个蛋白组分协同形成，其壳体装配、形态维持和压力稳定性均与蛋白序列特征密切相关。因此，从序列层面识别气囊蛋白中的潜在功能元件，有助于分析不同 GVP 蛋白在气囊形成过程中的功能分工，并为后续实验验证和工程设计提供参考。

1.1.2 气囊蛋白的应用价值

随着合成生物学、分子影像学和纳米生物材料研究的发展，气囊蛋白的应用价值逐渐受到关注。气囊内部气体与周围细胞质或组织介质之间存在明显声学性质差异，因此能够散射超声波并产生可检测的声学信号。这一特性使气囊蛋白从传统微生物浮力结构研究对象，发展为具有工程应用潜力的生物纳米结构^[4,10-11]。

在超声成像领域，Shapiro 等提出可将生物来源的气囊纳米结构作为超声分子报告物，用于产生非侵入式声学成像信号^[11]。与荧光成像相比，超声成像具有组织穿透深度较大、空间分辨率较高和临床转化基础较好等优势，因此气囊蛋白作为声学响应元件具有应用价值^[11]。随后，Lakshmanan 等通过分子工程方法调

控气囊蛋白纳米结构，证明气囊的机械性质、声学响应和表面功能可以通过工程化方式进行调节^[4]。

在报告基因和细胞追踪方向，Bourdeau 等提出 *acoustic reporter genes* 的概念，通过在工程化细菌中表达气囊基因簇，实现了对微生物在哺乳动物宿主体内分布状态的非侵入式超声监测^[12]。Hurt 等进一步通过基因组挖掘筛选不同来源的气囊基因簇，获得了适用于细菌和哺乳动物细胞的第二代声学报告基因，提高了成像信号和表达适配性^[13]。后续研究还通过高通量声学筛选和多重超声成像拓展了气囊蛋白的工程化应用^[14-15]。这些研究提示，气囊蛋白序列差异可能与其声学性能、表达稳定性和工程适配性有关。

因此，系统识别气囊蛋白中的关键功能元件，对于人工气囊设计、声学报告基因优化和新型细胞工程工具开发具有重要意义。

1.2 研究目的与意义

1.2.1 研究目的

本文旨在构建面向气囊蛋白序列的片段级计算分析流程，利用生物大模型提取气囊蛋白局部片段的向量表示，并结合降维聚类、保守性分析和结构辅助分析，识别气囊蛋白中的潜在功能元件，为后续气囊蛋白功能分析和工程改造提供计算参考。

1.2.2 理论意义

从理论层面看，本文有助于从序列表示角度分析气囊蛋白的潜在功能区域。气囊形成涉及多个 GVP 蛋白的协同作用，不同蛋白类型在序列长度、氨基酸组成、保守性和潜在结构特征方面存在差异。通过构建气囊蛋白数据集并提取模型嵌入表示，可以从局部层面分析不同气囊蛋白的序列特征，为理解气囊蛋白结构与功能关系提供依据。

从方法层面看，本文尝试将蛋白语言模型用于气囊蛋白这一特定蛋白体系。与传统依赖多序列比对、保守结构域检索和人工注释的方法相比，蛋白语言模型能够从大量无标注蛋白序列中学习潜在规律，提取包含上下文信息的高维表示^[16-18]。本文将模型嵌入与聚类分析、保守性分析和结构辅助分析相结合，有助于评估蛋白语言模型在特定蛋白家族功能元件识别中的适用性。

1.2.3 应用意义

从应用层面看,本文识别得到的候选功能元件可为人工气囊设计和气囊蛋白工程改造提供参考。已有研究表明,气囊蛋白可作为超声分子报告物和声学报告基因的重要组成部分,在非侵入式成像、细胞追踪和工程菌监测等方面具有应用潜力^[4,11-13]。识别与气囊结构稳定性、装配效率或声学响应相关的候选片段,有助于后续开展有针对性的突变设计和功能优化^[5-6,14-15]。

此外,本文构建的轻量化数据库原型可用于存储气囊蛋白序列、片段信息、聚类结果和候选元件信息,并通过可视化界面展示分析结果。

1.3 国内外研究现状

围绕气囊蛋白功能元件识别问题,国内外相关研究大体经历了从实验结构与功能研究、传统生物信息学分析、深度学习结构预测,到蛋白质大语言模型方法的发展过程。早期研究主要依赖冷冻电镜、突变实验等手段解析气囊结构以及 GvpA、GvpC 等关键蛋白的功能机制;随后,多序列比对、保守性分析、结构域搜索和共进化分析等方法逐渐用于蛋白功能区域识别;近年来,以 AlphaFold2 为代表的深度学习结构预测方法提高了蛋白三维结构推断能力,以 ESM-2 为代表的蛋白质大语言模型也增强了蛋白序列表示学习能力。



图 1-1 气囊蛋白功能元件识别相关研究技术演进图

1.3.1 实验结构与功能研究现状

如 1.1.1 节所述,气囊结构组成、形成机制及主要 GVP 蛋白功能已有一定研究基础。早期气囊蛋白研究主要依赖实验手段,常用方法包括显微观察、结构解析、突变实验、蛋白互作分析和力学性质测定等。这类方法能够从形态结构、蛋

白组成、关键位点突变效应和蛋白间相互作用等角度，为气囊蛋白功能分析提供较直接的证据。

在具体研究中，显微观察和结构解析方法可用于分析气囊整体形态、壳体结构和蛋白排列特征；突变实验可用于判断特定氨基酸位点或局部片段对气囊形成和稳定性的影响；蛋白互作实验可用于分析不同 GVP 蛋白之间的协同关系；力学性质测定则可用于评估气囊结构稳定性和抗压能力。这些实验方法为认识气囊形成机制和关键蛋白作用提供了重要依据。

然而，实验方法通常周期较长、成本较高、通量有限，难以系统覆盖多物种来源、多类型 GVP 蛋白及其大量局部片段。对于功能注释不足、同源性较低或候选片段边界不明确的气囊蛋白，仅依赖实验逐一筛选候选功能区域效率较低。

1.3.2 传统生物信息学方法研究现状

传统生物信息学方法是蛋白功能区域识别的重要基础，主要包括多序列比对、保守性分析、结构域搜索、共进化分析和同源比较等。多序列比对能够通过比较同源蛋白序列发现保守位点和保守片段，是蛋白功能元件识别中常用的方法之一^[19]。在此基础上，研究者通常进一步计算不同位点的保守程度，推测其是否与结构稳定、蛋白互作或功能执行有关。

对于气囊蛋白而言，不同物种来源的 GVP 蛋白序列差异可能较大，部分具有功能意义的片段未必表现出高度一致的序列保守性，因此单纯依赖保守性分析可能难以全面识别潜在功能元件。

结构域搜索和共进化分析也常用于蛋白功能区域推断。结构域搜索可以借助已有数据库识别蛋白序列中已知的功能模块；共进化分析则通过考察氨基酸位点之间的协同变化关系，推测蛋白内部接触位点或功能相关区域。这类方法通常需要数量充足、质量较高且同源关系明确的序列数据。对于部分辅助 GVP 蛋白，由于功能注释不足、序列数量有限或同源关系复杂，其分析效果可能受到限制。

1.3.3 深度学习结构预测方法研究现状

随着深度学习技术的发展，蛋白结构预测能力显著提升。以 AlphaFold 为代表的深度学习结构预测方法，能够从蛋白氨基酸序列出发预测其三维结构，为缺少实验结构的蛋白研究提供了重要参考^[20]。在蛋白功能元件识别任务中，结构预测方法可以从空间构象角度辅助解释候选片段的潜在功能意义，也可以为 GVP 蛋白局部功能区域分析提供空间依据^[20-21]。

不过，结构预测方法主要侧重蛋白三维结构推断，并不直接等同于功能元件识别。对于柔性区域、重复片段、低置信度区域或复合体装配相关片段，单体结

构预测结果仍需谨慎解释。此外，气囊结构形成涉及多个 GVP 蛋白之间的协同装配和相互作用，仅依赖单个蛋白的结构预测难以完整解释功能元件的作用。因此，结构预测更适合作为候选功能元件验证中的辅助证据，而不宜作为唯一判定依据。

1.3.4 蛋白质大语言模型研究现状

近年来，蛋白质大语言模型成为人工智能与生物信息学交叉领域的重要研究方向。该类模型将蛋白质氨基酸序列视为具有上下文关系的“生物语言”，通过在大规模蛋白序列数据上进行自监督预训练，学习氨基酸之间的组合规律、进化约束和潜在结构功能信息。与传统方法相比，蛋白质大语言模型能够从原始序列中自动提取高维表示，为蛋白功能预测、结构分析、突变效应评估和序列设计提供新的技术途径^[16-18]。

ESM 系列模型是蛋白质大语言模型的代表性工作之一。Rives 等通过大规模蛋白序列训练发现，模型表示中能够呈现与蛋白二级结构、接触关系和生物活性相关的信息^[16]。Lin 等进一步提出基于进化尺度语言模型的蛋白结构表征方法，表明蛋白语言模型能够从一级序列中学习较丰富的结构和功能信息^[18]。对于本文研究而言，ESM-2 能够为气囊蛋白提供残基级和片段级嵌入表示，有助于从局部片段层面分析潜在功能元件。

ProtTrans/ProtT5 和 ProGen 等模型也展示了蛋白语言模型在功能预测、结构分析和序列设计中的潜力^[17,22]。近年的研究表明，对蛋白语言模型进行任务微调可进一步提升多类蛋白预测任务表现^[23]。对于气囊蛋白功能元件识别任务而言，蛋白质大语言模型有助于突破表层序列相似性的限制，为低同源性、多物种蛋白片段分析提供新的表示空间。但模型结果仍具有一定黑箱性，模型嵌入和注意力信号不能直接等同于生物学功能。

1.4 现有研究存在的问题

1.4.1 功能元件边界缺乏统一判定标准

气囊蛋白功能元件的边界判定是当前研究中的难点之一。对于许多蛋白而言，功能区域不一定与完整结构域一致，也可能表现为较短的局部片段、重复序列、蛋白互作区域，或对结构稳定具有贡献的残基集合。气囊蛋白中 GvpC 的重复区域、GvpA 的壳体装配相关区域以及辅助蛋白中的互作片段，均可能具有功能意义^[5-6,8,21]。

现有研究对气囊蛋白关键区域的划分多依赖人工经验、少量突变实验或特定物种研究结果，缺少面向多类型、多来源气囊蛋白序列的系统化计算识别流程。不同研究关注的蛋白类型和实验体系不同，功能元件的定义、长度范围和筛选标准也不完全一致。因此，本文需要在研究中明确候选功能元件的计算定义，并通过统一流程提高元件识别的系统性和可复核性。

1.4.2 单一预测方法可靠性有限

在蛋白功能区域识别中，单独依赖某一种预测方法通常存在一定局限。若仅依赖多序列比对和保守性分析，可能忽略低保守但具有类别特异功能的区域；若仅依赖结构预测，则可能受到模型置信度、蛋白柔性区域和复合体状态缺失等因素影响^[20]；若仅依赖蛋白语言模型嵌入和聚类结果，则可能得到在表示空间上相似但缺少明确生物学解释的片段^[16-18]。

气囊蛋白功能元件识别尤其需要多维度证据支持。气囊结构形成涉及蛋白自组装、蛋白互作、机械稳定性和气体空间维持等多个因素，候选功能元件的可靠性不应只由单一指标决定。

1.5 本文主要研究内容与贡献

围绕气囊蛋白功能元件识别中存在的序列差异较大、功能片段边界不清和单一方法可靠性有限等问题，本文以多类型气囊蛋白序列为研究对象，结合蛋白语言模型、片段级表示学习、无监督聚类分析和多维度验证方法，构建面向气囊蛋白候选功能元件识别的计算分析流程。本文主要研究内容与贡献如下。

第一，构建气囊蛋白标准化数据集。本文基于指导教师本科课程《生物信息学》中三个小组整理的 GVP 蛋白序列数据，对原始数据进行汇总、格式统一、重复序列处理、异常序列筛查和蛋白类型规范化标注。研究对象覆盖 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 等八类气囊相关蛋白，为后续嵌入提取、片段分析和候选元件筛选提供结构化数据基础。

第二，设计基于 ESM-2 的片段级蛋白表示提取流程。本文利用蛋白语言模型 ESM-2 对气囊蛋白序列进行向量化表示，并通过滑动窗口策略将完整蛋白序列划分为局部片段，进一步提取片段级嵌入。与完整蛋白序列嵌入相比，片段级表示能够更细粒度地反映蛋白内部不同区域的序列特征，为候选功能元件定位提供向量基础。

第三，提出“降维聚类+位置稳定性+跨物种覆盖”的候选片段筛选策略。本文在片段级嵌入基础上，采用 UMAP 对高维表示进行降维，并使用 HDBSCAN

对片段进行无监督聚类，从而识别在表示空间中具有相似特征的片段群。随后结合片段在蛋白序列中的位置分布、同类蛋白中的重复出现情况以及跨物种覆盖情况，对聚类结果进行筛选和解释。

第四，建立多维度验证与结果整理流程。针对单一预测方法可靠性有限的问题，本文综合采用 ESM-2 注意力分析、MAFFT 多序列比对保守性分析、ESMFold 结构预测和 PyMOL 二级结构统计等方法，对候选片段进行多角度验证。同时，本文基于 SQLite 和 Streamlit 构建轻量化数据库原型，对候选元件的蛋白类型、物种来源、片段位置、片段序列和辅助验证信息进行结构化管理与可视化展示。

1.6 论文组织结构

本文共分为五章。第一章为绪论，主要介绍气囊蛋白的研究背景、应用价值以及气囊蛋白功能元件识别的研究意义；在此基础上，梳理国内外相关研究现状，分析现有研究中存在的主要问题，并概述本文研究内容与主要贡献。

第二章为理论基础与问题分析，主要介绍主要 GVP 蛋白类型、候选功能元件概念、蛋白序列与功能区域识别理论，并说明蛋白语言模型、片段级表示学习和多维度证据综合判断的理论基础。

第三章为研究方法，主要介绍气囊蛋白数据集构建、ESM-2 片段级嵌入提取、UMAP 降维、HDBSCAN 聚类、多维度验证以及数据库原型构建等方法。

第四章为实验结果与分析，主要展示气囊蛋白数据集统计结果、片段嵌入提取结果、降维聚类结果、位置稳定性与跨物种覆盖分析结果、多维度验证结果以及数据库原型展示结果，并对实验现象和候选片段特征进行分析。

第五章为总结与展望，主要总结本文完成的研究工作和取得的主要结论，分析研究中仍存在的不足，并从候选元件实验验证、模型方法优化和数据库功能完善等方面提出后续改进方向。

第二章 理论基础与关键技术

2.1 气囊蛋白及候选功能元件基础

2.1.1 主要 GVP 蛋白类型及功能

本文研究对象包括 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 等八类气囊相关蛋白。这些蛋白在气囊形成、结构稳定和功能维持中可能承担不同作用。其中，GvpA 和 GvpC 的研究基础相对充分，其他辅助蛋白的具体功能仍有待进一步明确。

GvpA 是气囊结构中的核心蛋白之一，通常被认为是气囊壳体的主要结构蛋白。GvpA 分子量较小、疏水性较强，在气囊壁层中以规则方式排列，参与形成气囊壳体的基本骨架^[1-2,21]。由于 GvpA 是气囊壳体的主要组成成分，其序列保守性、疏水性分布和局部结构特征可能直接影响气囊形态和稳定性^[1,21]。

GvpC 通常位于气囊外表面，与气囊机械稳定性密切相关。已有研究表明，GvpC 能够增强气囊抵抗外界压力的能力，其重复序列数量可能影响气囊直径和临界塌陷压力^[6]。因此，GvpC 中的重复区域、保守片段和外表面结合区域可能是影响气囊物理性质的重要功能元件^[5-6,21]。

GvpG、GvpJ 和 GvpK 等蛋白通常被认为属于气囊形成过程中的辅助相关蛋白，可能参与蛋白装配、形态控制或与其他 GVP 蛋白之间的相互作用^[3,7-8]。GvpN 和 GvpO 也与气囊形成过程密切相关，可能通过同源或异源相互作用参与装配调控^[5,8]。GvpP 的功能研究相对有限，但作为气囊相关蛋白，其序列特征可能与气囊基因簇功能维持或特定物种适应性有关。

综上，本文选择上述八类蛋白作为研究对象，既覆盖主要结构蛋白，也纳入功能机制尚不完全明确的辅助蛋白，为候选功能元件识别提供较完整的研究范围。

2.1.2 气囊蛋白候选功能元件的概念

本文中的气囊蛋白候选功能元件，是指气囊蛋白序列中可能与结构形成、稳定性维持、蛋白互作或功能调控相关的局部氨基酸片段。这类片段可以表现为连续保守区域、重复片段、结构稳定区域，也可以表现为在同类蛋白中具有相似位置分布或潜在功能意义的局部区域。需要说明的是，本文所称功能元件主要是计算预测意义上的候选功能片段，并不等同于已经通过湿实验验证的功能结构域。

2.2 蛋白序列与功能区域识别理论

2.2.1 蛋白序列与结构功能关系

从序列分析角度看，蛋白局部片段是连接一级序列和功能区域的重要分析对象^[24]。完整蛋白序列能够反映蛋白整体性质，但功能通常集中在某些特定区域。对于气囊蛋白而言，从片段级别开展分析有助于降低完整序列长度差异的影响，并提高候选功能区域定位的精细程度。

2.2.2 序列保守性与功能重要性的关系

序列保守性是蛋白功能区域识别中的重要依据。一般而言，如果某些氨基酸位点或片段在多个同源蛋白中长期保持相似，说明这些区域可能受到进化选择约束，并可能与蛋白结构稳定性或功能实现有关。多序列比对方法通过比较不同蛋白序列之间的相似性，发现潜在保守区域和关键位点。

不过，保守性并不直接等同于功能结论。一方面，并非所有保守片段都一定具有明确功能，有些保守性可能来源于结构约束或系统发育关系；另一方面，某些重要功能区域未必表现为高度序列保守，尤其在跨物种比较或功能趋同情况下，序列可能发生明显变化但仍维持相似结构或功能。

2.3 蛋白语言模型与片段级表示基础

2.3.1 蛋白语言模型的基本原理

蛋白语言模型将氨基酸序列看作一种“生物语言”，将常见氨基酸及特殊符号作为基本单元，通过预测序列中的氨基酸或学习上下文关系，获得蛋白序列的深层表示^[16-17]。

Transformer 是当前语言模型的重要基础架构。对于蛋白质序列而言，远距离氨基酸残基可能在三维结构中相互接近，或共同参与蛋白功能，因此自注意力机制适合用于蛋白序列表示学习。

自监督学习是蛋白语言模型训练的重要方式。模型不依赖人工标注标签，而是通过构造预测任务从原始序列中学习规律。掩码语言建模是常见自监督任务之一，其基本思想是随机遮蔽序列中的部分位置，并要求模型根据上下文预测被遮蔽的内容。ESM 系列模型正是在大规模蛋白序列上学习氨基酸上下文规律，从而获得包含结构和功能信息的嵌入表示^[16,18]。

2.3.2 片段级表示用于功能元件识别的依据

将蛋白序列划分为片段后进行分析，是功能区域定位中的常见思路。蛋白功能往往由局部区域承担，例如结构核心片段、蛋白互作界面、重复序列区域或保守功能位点。完整蛋白表示虽然能够反映整体特征，但难以直接定位具体功能区域。因此，片段级表示可以在完整序列和单个残基之间提供更合适的分析尺度。

对于气囊蛋白而言，片段级表示适合本文任务。气囊蛋白类型多样，序列长度差异明显，不同蛋白中可能存在局部保守片段或类别特异区域。如果只使用完整蛋白嵌入，模型可能更多反映蛋白整体差异，而难以发现局部功能模式。通过滑动窗口构建片段样本，可以将长短不一的蛋白序列转化为较统一的局部分析对象。

片段级表示还便于结合聚类和保守性分析。对于每个片段，既可以获得模型嵌入向量，也可以记录其所属蛋白类型、序列位置、片段长度和原始序列来源。若某些片段在同类蛋白中重复出现，并在嵌入空间中聚集，同时在多序列比对中表现出较高保守性，则这些片段更值得作为候选功能元件进行后续分析。

需要注意的是，片段级方法也会受到窗口长度、滑动步长和嵌入汇总方式的影响。窗口长度过短可能导致片段缺少上下文信息，窗口长度过长则可能降低定位精度。

2.4 关键技术原理

本节围绕气囊蛋白候选功能元件识别流程，介绍本文涉及的核心算法原理。

2.4.1 ESM-2 嵌入表示原理

ESM-2 蛋白语言模型用于将气囊蛋白序列转化为可计算的向量表示。气囊蛋白序列由离散氨基酸字符组成，不能直接用于聚类和相似性分析。ESM-2 基于 Transformer 结构，能够通过自监督学习捕捉氨基酸残基之间的上下文关系，并输出残基级嵌入^[16,18]。与传统人工特征相比，ESM-2 嵌入能够在不依赖显式功能标签的情况下保留一定的进化约束和潜在结构信息^[16,18]。本文利用该特性对滑动窗口生成的局部片段进行表示提取。

其核心自注意力机制可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-1)$$

其中， Q 表示查询矩阵， K 表示键矩阵， V 表示值矩阵， d_k 表示键向量维度。

ESM-2 对输入序列进行编码后，可以为每个残基生成一个高维嵌入向量。

$$h_i \in \mathbb{R}^d \quad (2-2)$$

式(2-2)中， h_i 表示第 i 个残基对应的嵌入表示， d 表示嵌入维度。

在本文中，片段级嵌入由片段内部残基嵌入汇总得到，可表示为式(2-3)。

$$z_F = \frac{1}{|F|} \sum_{i \in F} h_i \quad (2-3)$$

其中， F 表示候选片段或局部序列片段， $|F|$ 表示片段长度， z_F 表示该片段的嵌入向量。经过残基嵌入汇总后，原始氨基酸片段被转换为统一维度的数值特征。后续分析以这些片段嵌入为基础，进一步开展 UMAP 降维、HDBSCAN 聚类和候选片段筛选，从而将难以直接比较的蛋白序列转化为可计算、可聚类和可视化的向量数据。

2.4.2 UMAP 降维原理

ESM-2 输出的片段嵌入维度较高，难以直接观察不同片段之间的空间分布关系。UMAP 用于将高维嵌入映射到低维空间，使局部邻域结构能够通过二维图像呈现。其基本思想是在高维空间中构建样本之间的邻域图，再学习对应的低维表示，使低维邻域关系尽可能接近高维邻域关系。

设 p_{ij} 表示高维空间中样本 i 与样本 j 之间的邻域连接权重， q_{ij} 表示低维空间中样本 i 与样本 j 之间的邻域连接权重，则 UMAP 通过最小化二者之间的交叉熵损失实现降维，如式(2-4)所示。

$$C = \sum_{i \neq j} \left[p_{ij} \log \left(\frac{p_{ij}}{q_{ij}} \right) + (1 - p_{ij}) \log \left(\frac{1 - p_{ij}}{1 - q_{ij}} \right) \right] \quad (2-4)$$

其中， C 表示优化目标， p_{ij} 表示高维空间中的邻域相似度， q_{ij} 表示低维空间中的邻域相似度。UMAP 在本文中的作用不是直接判断片段功能，而是将高维嵌入中的局部邻域关系转化为可观察的二维分布。通过降维结果，可以初步判断不同蛋白类型片段是否存在聚集趋势，也可以为后续 HDBSCAN 识别高密度候选片段簇提供空间基础。

2.4.3 HDBSCAN 聚类原理

由于气囊蛋白功能元件缺少大规模实验标签，本文不适合直接采用监督分类方法。因此，在获得片段嵌入和 UMAP 降维结果后，本文采用 HDBSCAN 进行无监督聚类。HDBSCAN 是一种基于密度的层次聚类方法，能够在不预先设定簇数量的情况下识别高密度区域，并将难以归类的低密度样本标记为噪声点。

HDBSCAN 的核心计算之一是互达距离，可表示为式(2-5)。

$$d_{\text{mreach}}(a, b) = \max \{ \text{core}_k(a), \text{core}_k(b), d(a, b) \} \quad (2-5)$$

其中， $d_{\text{mreach}}(a, b)$ 表示样本 a 与样本 b 之间的互达距离， $\text{core}_k(a)$ 和 $\text{core}_k(b)$ 分别表示样本 a 、 b 到其第 k 个近邻的核心距离， $d(a, b)$ 表示两个样本之间的原始距离。互达距离同时考虑样本之间的距离和局部密度，有助于识别密度较稳定的片段群体。

在本文研究中，HDBSCAN 用于从大量气囊蛋白片段嵌入中发现具有相似表示特征的候选片段簇。与 K-means 等需要预先指定簇数的方法相比，HDBSCAN 更适合本文的探索性任务，因为候选功能元件的数量和分布并不明确，且部分片段可能不属于任何具有解释意义的簇。通过 HDBSCAN 输出的簇标签和噪声标签，后续可以进一步结合位置分布、跨物种覆盖、保守性和结构信息，对候选片段进行筛选与解释。

2.4.4 MSA 保守性分析原理

MSA 即多序列比对，是分析蛋白序列保守性的重要方法^[19]。其基本思想是将多条同源或同类蛋白序列按照可能对应的同源位置进行对齐，从而比较不同物种来源序列在相同位置上的氨基酸分布。如果某一位置或片段在多条序列中保持较高一致性，通常说明该区域可能受到进化约束，并可能与蛋白结构稳定性或功能维持有关。

对于比对位置 k ，保守性评分原理可表示为式(2-6)。

$$C_k = \max_{a \in A} p_{k,a} \quad (2-6)$$

其中， A 表示氨基酸集合， $p_{k,a}$ 表示氨基酸 a 在比对位置 k 上出现的频率。 C_k 越高，说明该位置越可能被某类氨基酸主导，具有较高保守性。该公式反映了保守性分析的基本思想，即通过氨基酸分布集中程度判断位点保守程度。

需要说明的是，式（2-6）仅用于说明保守性分析的基础思想。本文后续实际计算候选片段保守性时，采用基于 MAFFT 比对结果的信息熵归一化评分方法。该方法先统计比对列中标准氨基酸的频率分布，再计算信息熵并转换为归一化保守性分数；随后将位点分数映射回原始序列坐标，对候选片段范围内的多个位点进行汇总，得到片段级平均保守性分数。因此，后文使用的保守性指标可视为上述基础思想在片段层面的扩展，更适合衡量候选区域整体保守程度。

在本文中，MSA 主要用于从序列层面判断候选片段是否具有保守基础。若聚类得到的候选区域在多序列比对中对应较高保守位置，说明该区域可能受到一定进化约束，其作为候选功能元件的可信度会相应提高。

2.4.5 ESMFold 结构预测原理

ESMFold 用于从蛋白序列出发预测气囊蛋白的三维结构，为缺少实验结构的候选片段提供空间构象参考^[18]。ESMFold 利用蛋白质大语言模型学习得到的序列表示推断残基间关系，并输出蛋白质结构坐标。其结果可以帮助分析候选片段在蛋白结构中的空间位置、二级结构类型和局部结构分布。

ESMFold 的结构预测过程可以简化表示为式(2-7)。

$$X = \text{FoldTrunk}(\text{ESM}(S)) \quad (2-7)$$

其中， S 表示输入的蛋白质氨基酸序列， $\text{ESM}(S)$ 表示由蛋白质语言模型提取得到的序列表示， FoldTrunk 表示 ESMFold 中的结构预测模块， X 表示预测得到的蛋白三维结构坐标集合。

预测结构中第 i 个残基的三维坐标可表示为式(2-8)。

$$r_i = (x_i, y_i, z_i) \quad (2-8)$$

其中， r_i 表示第 i 个残基的三维空间位置， x_i 、 y_i 、 z_i 分别表示该残基在三维空间中的坐标值。通过将候选片段映射到预测结构中，可以观察其是否位于稳定二级结构区域、表面暴露区域或可能参与蛋白互作的位置。如果某一候选片段在嵌入空间中形成稳定聚类，同时在预测结构中位于可能影响蛋白稳定性、表面暴露或蛋白相互作用的位置，则该片段的候选功能意义更值得关注。

2.5 实验环境与技术实现基础

本文所需的软件环境与版本信息具体配置如表 2-1 所示。

表 2-1 实验环境配置

项目	配置或版本	用途
Python	3.11.15	数据处理与模型调用
PyTorch	2.12.0.dev20260408+cu128	ESM-2 模型推理
fair-esm	2.0.0	ESM-2 模型调用环境
ESM-2	ESM-2 35M; ESM-2 150M; ESM-2 650M	片段嵌入提取
scikit-learn	1.8.0	聚类质量评价指标计算
UMAP	0.5.11	嵌入降维与可视化
HDBSCAN	0.8.42	密度聚类分析
MAFFT	v7.526	多序列比对
PyMOL	3.1.0	结构渲染与二级结构统计
SQLite	3.53.0	候选片段结果存储
Streamlit	1.56.0	数据库原型界面展示

第三章 研究方法

3.1 方法设计动机

气囊蛋白候选功能元件识别的主要困难在于序列来源复杂、同源性差异明显、片段边界缺少明确标注。传统同源比对方法能够发现高度保守区域，但对于低同源性片段或类别特异区域，其识别能力有限；结构预测方法可以提供空间构象参考，但难以直接给出功能元件边界；蛋白语言模型能够从序列中提取上下文表示，但模型嵌入本身也不能直接等同于生物学功能结论。因此，仅依赖单一方法难以满足本文任务对候选区域定位和结果解释的要求。

基于上述考虑，本文采用片段级分析思路。与完整蛋白序列表示相比，片段级表示能够更细致地刻画蛋白内部不同局部区域的序列特征，也有助于降低不同 GVP 蛋白序列长度差异对分析结果的影响。本文先利用蛋白语言模型提取局部片段嵌入，再通过降维聚类发现表示空间中具有相似特征的片段群，从而获得候选区域的初筛结果。为避免将聚类结果直接解释为功能结论，后续进一步结合位置稳定性、跨物种覆盖、注意力分数、序列保守性和结构特征进行综合评价。由此形成“片段表示—候选筛选—多源验证”的分析框架。




图 3-1 现有方法局限与本文改进思路对比图

3.2 研究流程总体设计




图 3-2 研究流程总体设计图

本文研究流程如图 3-2 所示，整体上分为数据构建、候选片段筛选和多维度验证三个阶段。数据构建阶段主要完成 GVP 蛋白序列的合并、去冗余和异常过滤，并通过滑动窗口方法将完整蛋白序列转化为片段级分析对象。该阶段的输出包括清洗后的全长序列数据和带有位置信息的片段数据，为后续嵌入提取和候选区域定位提供基础。

候选片段筛选阶段以片段序列为输入，利用 ESM-2 提取片段级嵌入表示，并通过 UMAP 降维和 HDBSCAN 聚类识别表示空间中具有相似特征的片段簇。对于聚类结果，本文进一步结合片段在蛋白序列中的位置分布和跨物种覆盖情况进行筛选，并通过近距离冗余处理减少相邻滑动窗口带来的重复候选区域。

多维度验证阶段面向初筛得到的候选片段展开。本文分别从模型关注程度、序列保守性和预测结构特征三个角度进行分析：利用 ESM-2 注意力分数评估候选区域在完整序列中的相对重要性，利用 MAFFT 多序列比对计算候选片段保守性，并结合 ESMFold 结构预测和 PyMOL 二级结构统计分析候选区域的空间位置和结构特征。最终，将候选片段的位置、序列和验证指标整合到数据库中，用于后续查询和结果展示。

3.3 数据预处理

气囊蛋白序列来源较多，不同文件之间可能存在重复记录、注释格式不一致、序列截断以及非标准氨基酸字符等问题。若直接将原始序列用于片段构建和模型嵌入提取，可能会引入冗余样本或异常样本，从而影响后续聚类结果和候选区域判断。因此，本文在正式分析前对原始序列进行统一整理，主要包括数据来源确定、序列合并与去冗余、异常序列过滤以及结构化字段组织四个步骤。

3.3.1 数据来源与研究对象

本文使用的原始数据基于指导教师本科课程《生物信息学》中三个小组前期整理的 GVP 蛋白序列数据，序列来源主要可追溯至 NCBI 数据库中的 RefSeq 序列及标注为 **not partial** 的完整序列。为保证数据来源和后续处理过程具有可追溯性，本文在原始整理结果基础上进一步统一蛋白类型、序列编号、物种来源、蛋白名称和来源文件等注释信息。

本文研究对象包括 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 八类气囊相关蛋白。上述蛋白既包括气囊壳体形成和稳定维持过程中的主要结构蛋白，也包括可能参与气囊装配调控的辅助蛋白。经过初步整理后，每类 GVP 蛋白均形成独立的原始序列集合，为后续片段构建、模型嵌入提取、候选片段筛选和多维度验证提供数据基础。

3.3.2 序列合并与去冗余

由于原始序列来自多个文件和整理批次，同一蛋白可能存在重复收录或高度相似记录。为降低冗余序列对统计结果和聚类分布的影响，本文首先按照蛋白类型合并同类 GVP 蛋白序列，随后采用 CD-HIT 进行序列去冗余处理^[25]。去冗余相似性阈值设置为 0.95，即当两条序列相似度达到或超过 95% 时，将其归入同一聚类簇，并保留其中一条代表序列用于后续分析。

在去冗余过程中，本文并未直接丢弃同簇冗余序列的注释信息，而是将其作为代表序列的来源补充信息进行保留。这样既可以减少后续模型推理和聚类分析中的重复计算，又能够在候选片段解释阶段追溯其物种来源和冗余成员分布，为跨物种覆盖分析提供依据。

3.3.3 数据清洗与 JSON 字段组织

在获得去冗余代表序列后，本文进一步对序列质量进行检查。首先，过滤含有非标准氨基酸字符的序列，仅保留由 20 种标准氨基酸组成的蛋白序列。其次，根据不同 GVP 蛋白类型的序列长度分布，剔除明显偏离正常范围的异常序列，以减少截断序列、错误注释序列或异常拼接序列对后续分析的影响。

清洗后的序列同时保存为 FASTA 和 JSON 两种格式。FASTA 文件主要用于模型嵌入提取和多序列比对；JSON 文件用于保存结构化元信息，包括序列编号、蛋白类型、氨基酸序列、物种来源、代表序列注释、冗余簇成员以及来源文件等字段。经过上述处理后，原始序列被整理为可直接用于程序读取、片段构建和结果追溯的标准化数据集。

3.4 蛋白片段级嵌入提取方法

气囊蛋白功能区域通常表现为局部片段，而不一定对应完整蛋白序列或明确结构域。若直接使用全长序列表示，不同 GVP 蛋白之间的长度差异和整体序列差异可能掩盖局部功能片段的特征。因此，本文采用滑动窗口方法将全长蛋白序列划分为局部片段，并利用蛋白语言模型提取片段级嵌入表示。该方法能够在保留局部上下文信息的同时，为后续降维聚类 and 候选区域定位提供统一维度的数值特征。

3.4.1 蛋白语言模型选择

本文选用 ESM-2 作为蛋白序列表示模型。该模型基于 Transformer 结构，通过大规模蛋白序列自监督学习获得氨基酸上下文表示，能够在不依赖人工功能标签的情况下提取序列中的潜在进化、结构和功能信息。对于本文所研究的气囊蛋白，部分蛋白存在功能注释不足、同源性差异较大等问题，采用蛋白语言模型提取片段表示，有助于弥补传统人工特征和单纯多序列比对方法的不足。

在具体实现中，本文使用 ESM-2 对滑动窗口生成的片段序列进行编码，输出对应的残基级表示；随后通过平均池化将残基表示汇总为片段级嵌入。经过该处理，不同来源的局部片段被转换为统一维度的向量表示，可作为后续距离计算、降维和聚类分析的输入。

3.4.2 滑动窗口片段构建

在获得清洗后的代表序列后，本文采用滑动窗口方法构建片段级分析对象。每个窗口对应蛋白序列中的一个连续氨基酸片段，并记录其所属蛋白类型、序列编号、物种来源、起始位置、终止位置和片段序列。通过这种方式，完整蛋白序列被转化为带有位置信息的局部片段集合，使后续分析能够在局部区域尺度上进行，而不只依赖全长蛋白的整体特征。

不同 GVP 蛋白的序列长度和潜在功能区域尺度并不一致，因此本文未采用统一窗口参数，而是根据不同蛋白类型分别设置窗口长度和滑动步长。窗口长度主要影响片段所包含的上下文范围，步长则影响候选区域定位的精细程度。对于长度较短、结构功能区域相对集中的蛋白，较短窗口有利于提高局部片段定位精度；对于长度较长或可能包含连续功能区域的辅助蛋白，适当增大窗口长度有助于保留更完整的上下文信息。同时，滑动步长的设置可以在计算量和定位精度之间取得平衡，避免生成过多高度重叠的冗余片段。不同 GVP 类型的窗口参数设置如表 3-1 所示。

表 3-1 不同 GVP 类型的滑动窗口与初筛参数设置

GVP 类型	窗口长度	步长	主体模型	min_cluster_plot
GvpA	30	5	ESM-2 35M	200
GvpC	35	8	ESM-2 35M	50
GvpN	40	8	ESM-2 35M	200
GvpO	50	5	ESM-2 35M	200
GvpG	25	5	ESM-2 35M	150
GvpJ	35	10	ESM-2 35M	150
GvpK	25	4	ESM-2 35M	50
GvpP	40	10	ESM-2 35M	50

3.4.3 片段嵌入提取与归一化

对于每个滑动窗口片段，本文利用 ESM-2 获得其残基级嵌入表示，并通过平均池化得到片段级向量。该处理方式可以将不同长度和不同来源的片段转换为统一维度的数值表示，便于后续开展距离计算、降维和聚类分析。

为减少向量尺度差异对距离度量和聚类结果的影响，本文进一步对片段嵌入进行归一化处理。归一化后的片段记录同时保留蛋白类型、物种来源、序列位置和片段序列等信息。最终得到的片段级嵌入矩阵作为后续 UMAP 降维和 HDBSCAN 聚类分析的输入。

3.5 降维聚类与候选片段初筛方法

在获得片段级嵌入矩阵后，本文需要从大量局部片段中筛选出具有相似序列表示特征的候选区域。由于片段嵌入维度较高，直接在原始高维空间中观察片段分布较为困难，也不利于后续聚类结果解释。因此，本文先采用 UMAP 对片段嵌入进行低维映射，再利用 HDBSCAN 识别低维空间中的高密度片段簇。该过程的目的是不是直接判定片段功能，而是从表示空间中获得候选片段集合，为后续位置稳定性、跨物种覆盖和多维度验证提供初筛结果。

3.5.1 UMAP 与 HDBSCAN 参数设置

本文以归一化后的片段嵌入矩阵作为输入，首先利用 UMAP 将高维嵌入映射到二维空间。UMAP 能够较好保留样本之间的局部邻域关系，适合用于观察不同片段在表示空间中的聚集趋势。随后，本文采用 HDBSCAN 对降维后的片

段进行密度聚类。与需要预先指定簇数量的聚类方法相比，HDBSCAN 能够根据样本密度自动识别簇结构，并将难以归类的片段标记为噪声点，更适合本文这种候选功能区域数量未知、片段分布不均匀的探索性任务。

针对不同 GVP 蛋白类型，本文分别设置 UMAP 和 HDBSCAN 参数。UMAP 参数主要包括 `n_neighbors`、`min_dist`、`metric` 和 `random_state`，其中 `n_neighbors` 影响局部邻域范围，`min_dist` 影响低维空间中样本的紧凑程度。HDBSCAN 参数主要包括 `min_cluster_size`、`min_samples`、`metric` 和 `cluster_selection_epsilon`，其中 `min_cluster_size` 用于控制最小簇规模，`min_samples` 影响噪声点判定的严格程度。不同 GVP 类型的序列数量、片段数量和片段分布存在差异，因此本文未采用完全统一的参数，而是结合各类蛋白的片段规模和初步可视化结果进行设置。具体参数如表 3-2 所示。

表 3-2 不同 GVP 类型的 UMAP 与 HDBSCAN 参数设置

GVP 类型	UMAP <code>n_neighbors</code>	UMAP <code>min_dist</code>	UMAP <code>metric</code>	HDBSCAN <code>min_cluster_size</code>	HDBSCAN <code>min_samples</code>	<code>cluster_selection_epsilon</code>
GvpA	20	0.15	euclidean	40	12	—
GvpC	30	0.1	euclidean	50	20	—
GvpN	23	0.08	euclidean	70	25	0.15
GvpO	15	0.2	euclidean	20	1	—
GvpG	18	0.1	euclidean	35	10	—
GvpJ	22	0.15	euclidean	40	12	0.1
GvpK	15	0.1	euclidean	30	8	—
GvpP	15	0.13	euclidean	20	8	0.15

3.5.2 聚类结果评价方法

为评价不同 GVP 类型的聚类效果，本文在 HDBSCAN 聚类后计算 Calinski-Harabasz 指数、Davies-Bouldin 指数和轮廓系数等无监督聚类评价指标[26-28]。其中，Calinski-Harabasz 指数反映簇间离散程度与簇内紧密程度的相对关系，数值越大通常说明聚类结构越清晰；Davies-Bouldin 指数用于衡量簇内分散程度与簇间分离程度，数值越小通常说明簇间区分度越高；轮廓系数综合考虑样本与本簇样本及最近其他簇样本之间的距离差异，取值越高表示样本归属越明确。

需要说明的是，上述指标主要用于辅助判断聚类结果的整体质量，并不单独作为候选功能区域的判定标准。由于气囊蛋白片段可能存在密度不均、边界模糊

和噪声样本较多等情况，仅依据聚类评价指标容易忽略生物学解释。因此，本文在聚类结果基础上进一步引入位置稳定性、跨物种覆盖和后续多维度验证，以提高候选片段筛选的可靠性。

3.5.3 位置稳定性与跨物种覆盖分析

聚类结果只能说明部分片段在嵌入空间中具有相似特征，但不能直接说明这些片段具有稳定的功能意义。对于候选功能元件而言，如果同一聚类簇中的片段在不同序列中集中出现在相近位置，并且覆盖多个物种来源，则该簇更可能对应具有一定保守性或代表性的候选区域。因此，本文从位置稳定性和跨物种覆盖两个角度对聚类簇进行进一步筛选。

本文使用起始位置变异系数衡量簇内片段位置稳定程度。其计算方式为：

$$CV = \frac{s}{m} \quad (3-1)$$

式中， s 表示同一簇内片段起始位置的标准差， m 表示同一簇内片段起始位置的平均值。 CV 值越小，表示该簇片段在不同序列中的起始位置越集中； CV 值越大，则表示该簇片段位置分布越分散。本文将 CV 作为候选簇初步分级的重要指标之一。

除位置稳定性外，本文还统计每个聚类簇覆盖的物种数量。对于每一类 GVP 蛋白，先统计该类型数据集中所有有效物种数量，再将跨物种覆盖阈值设置为总物种数的 20%。若某一聚类簇覆盖物种数达到该阈值，则认为该簇具有一定跨物种代表性。初筛阶段将同时满足跨物种覆盖比例达到 20% 且 CV 小于 0.6 的聚类簇纳入候选片段集合。该阈值主要用于平衡候选区域的覆盖范围和位置稳定性，候选片段的最终解释仍需结合后续注意力分数、序列保守性和结构特征综合判断。

3.5.4 近距离候选片段后处理

由于本文采用滑动窗口方法构建蛋白片段，相邻窗口之间通常存在较高比例的序列重叠。因此，在候选片段初筛后，同一 GVP 类型中可能出现多个起始位置非常接近的候选区域。这类候选片段往往来源于相邻窗口，可能对应同一局部功能区域。若全部保留，容易造成候选结果重复，并增加后续验证和数据库展示的冗余。

为减少滑动窗口带来的近距离重复候选区域，本文在候选片段初筛后进行后处理。具体而言，先按照 GVP 蛋白类型对候选片段进行分组，并将候选片段的平均起始位置向下取整，得到统一的候选起始位置；随后根据对应蛋白类型的窗口长度确定候选片段终止位置。对于同一 GVP 类型内的候选片段，按照起始位

置从小到大排序。第一个候选片段默认保留；对于后续候选片段，若其起始位置与上一个已保留候选片段的距离小于 5 个氨基酸，则认为二者对应相近区域，删除当前候选片段；若距离大于或等于 5 个氨基酸，则保留该候选片段。

经过近距离后处理后，本文得到最终候选片段列表。该列表作为后续 ESM-2 注意力分数分析、MAFFT 多序列比对保守性评分、ESMFold 结构预测和 PyMOL 二级结构统计的输入。通过该步骤，可以在保留主要候选区域的同时降低相邻窗口冗余，使后续多维度验证结果更加清晰。

3.6 候选片段多维度验证方法

经过降维聚类 and 候选片段初筛后，得到的候选区域仍主要来源于片段嵌入空间中的相似性。该结果能够反映序列表示特征上的聚集关系，但不能直接等同于功能结论。为提高候选片段解释的可靠性，本文进一步从模型关注程度、序列保守性和预测结构特征三个角度进行验证。不同证据分别对应候选区域的表示重要性、进化约束程度和结构可解释性，共同用于候选功能区域的综合评价。

3.6.1 ESM-2 注意力分数分析

为评估候选片段在完整蛋白序列表示中的相对重要性，本文使用 ESM-2 35 M 模型对清洗后的全长蛋白序列进行编码，并提取模型输出的注意力权重。与片段嵌入提取不同，注意力分数分析以完整蛋白序列为输入，目的是考察候选区域在全长序列上下文中受到模型关注的程度。

设模型共有 L_h 层、 H 个注意力头，第 l 层第 h 个注意力头中位置 i 到位置 j 的注意力权重为 $A_{ij}^{(l,h)}$ ，则平均注意力权重可表示为：

$$\bar{A}_{ij} = \frac{1}{L_h H} \sum_{l=1}^{L_h} \sum_{h=1}^H A_{ij}^{(l,h)} \quad (3-2)$$

在得到平均注意力矩阵后，本文对每个残基位置接收到的注意力进行求和，用于表示该残基在完整序列中被其他位置关注的程度。设完整蛋白序列长度为 N ，则第 j 个残基的注意力重要性分数可表示为：

$$b_j = \sum_{i=1}^N \bar{A}_{ij} \quad (3-3)$$

由于 ESM-2 输入序列中包含 cls 和 eos 等特殊标记，程序在计算残基层面注意力分数时去除了这些特殊标记，仅保留真实氨基酸位置对应的注意力分数。随后，本文在每条完整蛋白序列内部对注意力分数进行归一化处理，使其映射到 0 到 1 范围内。归一化公式为：

$$a_j = \frac{b_j - \min(b)}{\max(b) - \min(b)} \quad (3-4)$$

其中, b_j 表示第 j 个残基归一化前的注意力分数, a_j 表示归一化后的注意力分数。当同一序列内最大值与最小值差异过小时, 程序将该序列的注意力分数置为 0, 以避免分母过小造成数值不稳定。

对于每个候选片段, 本文直接读取最终去重候选区域表中的 `start_floor` 和 `end_floor` 作为片段起止位置, 不再重新进行候选区域筛选、起始位置取整或近距离去重。若候选片段终止位置超过当前蛋白序列长度, 则将终止位置截断为该序列长度; 若截断后片段长度不足原候选区域长度的一半, 则跳过该序列中的该候选片段, 以避免过短片段影响平均注意力分数的可靠性。设候选片段的实际起始位置和终止位置分别为 s 和 e , 并将片段视为左闭右开区间 $[s, e)$, 则该片段的平均注意力分数计算为:

$$A_{\text{frag}} = \frac{1}{e-s} \sum_{j=s}^{e-1} a_j \quad (3-5)$$

其中, a_j 表示第 j 个残基归一化后的注意力分数, A_{frag} 表示候选片的平均注意力分数。该分数越高, 说明该候选片段在对应完整蛋白序列的模型注意力分布中越突出。

除平均注意力分数外, 本文还计算该片段平均注意力分数在当前完整蛋白序列内部的百分位排名。百分位排名用于评价候选片段相对于该条蛋白序列其他残基位置的突出程度, 其计算方式为:

$$P_{\text{att}} = \frac{\sum_{j=1}^N I(a_j \leq A_{\text{frag}})}{N} \times 100\% \quad (3-6)$$

其中, $I()$ 为指示函数, 若括号内条件成立则取 1, 否则取 0; N 表示完整蛋白序列长度; P_{att} 表示候选片段平均注意力分数在该序列内部的百分位排名。百分位越高, 说明该候选片段在模型注意力分布中相对越突出。

在完成单条序列的候选片段注意力计算后, 本文进一步按照 `cluster_id` 和片段位置对结果进行汇总。对于同一候选区域, 程序统计其不同来源序列中的平均注意力分数、注意力标准差和平均百分位排名。设某一候选区域共有 n 条有效序列参与统计, 第 r 条序列中该候选片段的注意力分数为 $A_{\text{frag}, r}$, 则该候选区域的平均注意力分数为:

$$\bar{A}_{\text{frag}} = \frac{1}{n} \sum_{r=1}^n A_{\text{frag}, r} \quad (3-7)$$

对应的注意力标准差为:

$$s_A = \sqrt{\frac{1}{n-1} \sum_{r=1}^n (A_{\text{frag},r} - \bar{A}_{\text{frag}})^2} \quad (3-8)$$

候选区域的平均百分位排名为：

$$\bar{P}_{\text{att}} = \frac{1}{n} \sum_{r=1}^n P_{\text{att},r} \quad (3-9)$$

其中， A_{frag} 表示候选区域的平均注意力分数， s_A 表示注意力标准差， P_{att} 表示候选区域的平均百分位排名。最终，本文将每个候选片段的注意力分数、注意力标准差和平均百分位保存为统计表，用于第四章中候选片段 ESM-2 注意力分数结果展示。

需要说明的是，ESM-2 注意力分数反映的是模型在序列表示过程中对不同残基位置的相对关注程度，不能直接等同于候选片段的生物学功能。本文仅将其作为模型层面的辅助证据，并结合多序列比对保守性、结构预测位置和二级结构特征进行综合判断。

3.6.2 MAFFT 多序列比对与保守性评分

ESM-2 注意力分数主要反映模型表示层面的关注程度，仍需结合传统序列分析方法判断候选片段是否具有进化保守性。为此，本文采用 MAFFT 对同一 GVP 类型的清洗后全长蛋白序列进行多序列比对^[29]，并在比对结果基础上计算候选片段的保守性分数。该步骤用于评估候选区域在不同物种来源的同类蛋白中是否保持相对稳定，从而为候选功能元件判断提供序列层面的证据。

具体而言，本文分别对 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 八类蛋白构建多序列比对结果。由于比对后的序列中可能包含插入缺失符号，程序在计算保守性时仅统计标准氨基酸字符，并忽略无有效氨基酸的比对列。对于每一个有效比对位置，本文根据该列中 20 种标准氨基酸的频率分布计算信息熵。设某一比对列中第 i 种氨基酸的频率为 p_i ，则该列的信息熵 H 为：

$$H = -\sum_{i=1}^{20} p_i \log_2 p_i \quad (3-10)$$

信息熵越低，说明该位置的氨基酸组成越集中，保守性越强；信息熵越高，则说明该位置变异程度越大。为便于不同位置之间比较，本文进一步将信息熵转换为归一化保守性分数 S ：

$$S = 1 - \frac{H}{\log_2(20)} \quad (3-11)$$

式中，20 表示标准氨基酸种类数量。 S 越接近 1，表示该比对列中氨基酸组成越集中，序列保守性越强； S 越接近 0，则表示该位置氨基酸组成越分散，变异程度越高。

由于 MAFFT 比对结果中包含插入缺失符号，本文进一步将比对列的保守性分数映射回每条原始序列的坐标系。具体而言，以每条序列自身为参考，遍历其比对后的序列，跳过缺口位置，仅将有效氨基酸对应的比对列分数投回原始序列位置。随后，根据候选片段在原始序列中的起止坐标，提取对应区域内各位置的保守性分数，并计算片段平均保守性分数。

为便于不同长度序列和不同候选片段之间进行相对比较，本文进一步计算候选片段平均保守性分数的百分位排名。该百分位排名的计算方式与前文公式(3-6)注意力分数百分位排名方法一致，即以同一条序列中所有有效位置的保守性分数分布作为背景，统计候选片段平均保守性分数在该分布中的相对位置。

最终，本文将候选片段的平均保守性分数和百分位排名保存为统计结果，用于第四章中多序列比对保守性分析结果展示。需要说明的是，保守性分数主要反映候选片段可能受到的进化约束，不能单独作为功能判定依据，仍需与模型注意力分数和结构特征共同解释。

3.6.3 ESMFold 结构预测方法

模型注意力和序列保守性主要从一维序列角度评价候选片段，仍难以反映候选区域在蛋白空间结构中的位置特征。由于部分气囊蛋白缺少实验解析结构，本文采用 ESMFold 对气囊蛋白序列进行结构预测^[18]，为候选片段提供三维结构参考。

在具体分析中，本文根据候选片段所属 GVP 类型和物种来源，选取对应代表序列进行结构预测，并生成 PDB 格式结构文件。随后，将候选片段的起止坐标映射到预测结构中，用于观察其在蛋白空间构象中的位置分布。若某一候选区域在多个代表序列的预测结构中均位于相近结构区域，或表现出较稳定的二级结构特征，则说明该区域具有进一步分析价值。需要说明的是，ESMFold 预测结果主要用于辅助解释候选片段的结构特征，不能替代实验解析结构或功能验证结果。

3.6.4 PyMOL 二级结构统计与结构评分

获得 ESMFold 预测的 PDB 文件后，本文使用 PyMOL 对预测结构进行渲染和二级结构统计。PyMOL 的 dss 功能可根据结构坐标重新识别残基的二级结构类型，包括 α 螺旋、 β 折叠和其他非规则结构。本文重点统计候选片段中处于 α 螺旋或 β 折叠状态的残基比例，以评估该区域是否具有相对稳定的局部结构特征。

在具体计算中，本文以候选片段内可识别的 C_α 原子数量近似表示残基数量。 C_α 原子是氨基酸残基主链中的 α -碳原子，在 PDB 文件中通常记为 CA；对于标

准蛋白结构，每个残基通常对应一个 C_α 原子。因此，统计候选片段范围内的 C_α 原子数量，可以近似表示该片段中可识别的残基数量。在此基础上，进一步统计其中属于 α 螺旋或 β 折叠状态的残基数量，并计算单个预测结构中的二级结构残基占比：

$$R_{ss} = \frac{N_{HS}}{N_{CA}} \quad (3-12)$$

其中， R_{ss} 为单个候选片段预测结构中 α 螺旋或 β 折叠残基所占比例；分子 N_{HS} 表示属于 α 螺旋或 β 折叠状态的 C_α 原子数量；分母 N_{CA} 表示该候选片段中全部 C_α 原子数量。由于蛋白结构中通常每个氨基酸残基对应一个 C_α 原子，因此该比例可用于近似表示候选片段中二级结构残基所占比例。

对于单个预测结构，若其中存在 α 螺旋或 β 折叠残基，则记为 1；否则记为 0。同一候选区域包含 5 条不同属代表序列的预测结构，因此本文进一步计算区域层面的二级结构总分，其计算方式为：

$$T_{ss} = \sum_{j=1}^N I_j \quad (3-13)$$

其中：二级结构总分 T_{ss} 对应数据库字段 `ss_total_score`，表示同一候选区域中具有 α 螺旋或 β 折叠结构的代表结构数量； N 表示该候选区域实际完成结构预测的序列数量；单个结构标记 I_j 表示某一预测结构是否存在 α 螺旋或 β 折叠残基。若该预测结构存在 α 螺旋或 β 折叠残基，则单个结构标记为 1；否则记为 0。

在此基础上，本文计算区域层面的二级结构比例分数，其计算方式为：

$$P_{ss} = \frac{T_{ss}}{N} \quad (3-14)$$

其中：二级结构比例分数 P_{ss} 表示序列中 α 螺旋或 β 折叠结构所占比例； T_{ss} 为二级结构总分公式(3-13)得到的结果； N 为该候选区域实际完成结构预测的序列数量。该比例分数越接近 1，表示该候选区域在不同代表序列预测结构中越稳定地出现 α 螺旋或 β 折叠结构；该比例分数越接近 0，则表示该区域在预测结构中缺少明显二级结构特征。

若某一区域在多个代表结构中均呈现一定二级结构特征，则该片段可能具有相对稳定的结构倾向；若多个代表结构均缺少明显二级结构，则该片段可能较为柔性或缺少稳定局部构象。结构评分结果同样不作为单一判定标准。气囊蛋白中部分功能区域可能并非稳定二级结构区域，而可能通过柔性、重复或蛋白互作发挥作用。因此，本文将结构评分与注意力分数、MSA 分数、聚类位置稳定性和跨物种覆盖共同整合，用于候选片段的综合分析。

需要说明的是，二级结构评分仅反映候选片段在预测结构中的局部结构倾向，不能单独作为功能判定依据。部分气囊蛋白功能区域可能并不表现为稳定螺旋或

折叠，而是通过柔性片段、重复序列或蛋白互作发挥作用。因此，本文将结构评分与 ESM-2 注意力分数、MAFFT 保守性分数、聚类位置稳定性和跨物种覆盖结果共同整合，用于候选片段的综合评价。

3.7 结果整合与数据库构建方法

完成候选片段初筛和多维度验证后，本文需要对不同分析模块产生的结果进行统一组织。由于候选片段相关信息来源于聚类筛选、位置稳定性分析、跨物种覆盖统计、ESM-2 注意力分数、MAFFT 保守性评分以及结构特征统计等多个环节，若分别保存和查询，容易造成结果分散，影响后续比较和展示。因此，本文以候选片段为基本单位，对多源结果进行整合，并构建轻量化数据库用于结果存储、检索和可视化展示。

3.7.1 多源结果整合方法

本文以最终去重后的候选片段作为结果整合的基本记录单位。每条记录保留候选片段的基础信息，包括 GVP 类型、蛋白编号、物种来源、片段起止坐标和片段序列；同时补充候选片段对应的聚类编号、位置稳定性指标、跨物种覆盖比例、注意力分数、保守性评分和二级结构统计结果。

在整合过程中，不同分析步骤产生的数据主要通过 GVP 类型、蛋白编号和片段坐标进行关联。对于同一候选片段，数据库中同时保存其聚类来源、序列位置、模型关注程度、序列保守性水平和结构辅助信息。对于起始位置相近、可能对应同一局部区域的候选片段，本文依据前述近距离后处理结果保留代表性片段，以减少数据库中的重复记录，并提高后续查询和展示的清晰度。

3.7.2 SQLite 单表数据库设计

本文采用 SQLite 构建本地轻量化数据库，数据库文件名为 `gvp_web.db`，主表名称为 `sequence_records`。SQLite 无需额外部署服务器，便于在本地环境中完成候选片段结果的存储、更新和查询，适合本文当前阶段的数据规模和展示需求。

`sequence_records` 表用于存储候选片段及其验证结果，主要字段包括 GVP 类型、蛋白编号、物种来源、基因名称、候选片段起止位置、完整序列、窗口序列、聚类编号、跨物种占比、起始位置 CV 、注意力平均分数、MAFFT 保守性分数、二级结构评分、PDB 文件路径和图片路径等。相比多表结构，单表设计更便于 Streamlit 前端直接读取、筛选和展示，也能降低当前原型系统的维护复杂度。

在数据库写入过程中，本文以 `gvp_type`、`accession`、`start_pos` 和 `end_pos` 作为关键字段，对候选记录进行去重和更新。若同一候选片段已存在于数据库中，则根据导入模式选择保留原记录、覆盖原记录或补充更新部分字段。对于后续新增的 `full_sequence`、`window_seq`、结构文件路径和图像路径等信息，程序通过关键字段匹配的方式写入对应记录。通过上述设计，候选片段的序列信息、聚类结果和验证指标能够在同一数据表中统一管理，为后续结果展示和人工复核提供支持。

3.8 参数设置与参数敏感性分析

本文涉及的主要参数包括滑动窗口长度、滑动步长、UMAP 降维参数、HDBSCAN 聚类参数和候选片段筛选阈值。由于 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 八类蛋白在序列长度、片段数量和嵌入空间分布上存在差异，本文未采用完全统一的参数设置，而是结合不同蛋白类型的序列特征、计算规模和聚类结果进行调整。具体窗口参数、主体模型以及 UMAP 和 HDBSCAN 参数已分别列于表 3-1 和表 3-2，本节主要说明参数确定依据和敏感性分析设计。

本文未采用完整网格搜索或贝叶斯优化方法。原因在于，本文任务属于无监督候选片段发现，缺少经过实验验证的功能元件标签，难以使用准确率、召回率等监督指标作为唯一优化目标。同时，不同参数组合均需重新进行片段生成、嵌入处理、降维聚类 and 候选统计，在多种 GVP 蛋白和不同模型规模下会带来较高计算开销。因此，本文主要结合片段生成数量、有效簇数量、噪声点比例、聚类评价指标、候选片段位置稳定性和跨物种覆盖情况确定参数。

在滑动窗口参数方面，本文根据蛋白序列长度和潜在功能片段尺度进行设置。对于 GvpA 等短序列蛋白，窗口长度设置相对较小，以提高局部区域定位精度；对于 GvpC、GvpN 等较长序列蛋白，适当增大窗口长度，以覆盖较完整的局部上下文信息，并减少过短片段带来的噪声。滑动步长则用于平衡片段覆盖密度和计算冗余，避免步长过大导致候选区域遗漏，也避免步长过小产生大量高度重叠片段。

在 UMAP 参数方面，本文主要关注低维嵌入空间中的局部聚集程度和簇间分离情况。邻居数用于平衡局部结构和整体结构，过小可能导致结果碎片化，过大则可能削弱局部簇差异；最小距离影响样本点在低维空间中的紧密程度，过小可能导致局部结构过度压缩，过大则可能使候选片段分布过于分散。因此，本文选择能够保持片段分布可分性和稳定性的参数组合。

在 HDBSCAN 参数方面，本文主要关注最小簇大小和最小样本数。最小簇大小过小容易产生碎片化簇，过大则可能合并不同来源或不同位置的片段；最小样本数过大会提高核心点判定要求，使噪声点比例升高，过小则可能保留稳定性不足的弱簇。因此，本文综合考虑有效簇数量、噪声点比例、簇内紧密性、簇间分离度和候选片段位置集中程度，使聚类结果既具有一定区分能力，又能保留后续验证所需的候选片段。

最终参数选择不以某一个聚类评价指标最优作为唯一依据，而是综合考虑聚类结构、候选片段数量、位置稳定性、跨物种覆盖情况和后续验证可行性。轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数和噪声比例主要作为辅助评价指标；候选簇的起始位置变异系数和跨物种覆盖比例则用于判断聚类结果是否适合进入后续验证流程。

此外，为考察参数变化对候选区域识别结果的影响，本文以 GvpA 为例开展参数敏感性测试。在原始参数组基础上设置四组小范围扰动参数，共形成五组参数组合。参数组 1 为原始参数组，参数组 2 和参数组 3 分别表示整体小幅减小和整体小幅增大，参数组 4 用于增强局部结构分辨能力，参数组 5 用于提高聚类保守性。详细参数设置见附录表 A-1。该实验用于检验不同参数条件下候选区域是否仍能与原始参数结果保持一致，从而评估候选功能元件识别流程的稳定性。




图 3-3 GvpA 参数敏感性分析结果

由图可见，GvpA 在 5 组参数中的候选区域匹配比例分别为 100%、100%、100%、60%和 100%。除参数组 4 外，其余参数组均能复现原始结果，说明方法整体稳定；参数组 4 的匹配比例下降，表明局部结构分辨参数会对部分聚类结果产生影响。

第四章 实验结果与分析

4.1 数据集构建

在数据整理阶段，本文对 3.3.2 节得到的合并序列集合采用 CD-HIT 进行去冗余。在清洗阶段，过滤含有非标准氨基酸字符的序列，并剔除长度超出同类蛋白长度均值 ± 3 倍标准差范围的异常序列。表 4-1 列出了各清洗步骤后的序列保留情况。

表 4-1 气囊蛋白序列清洗结果统计

Gvp 类型	原始序列数	CD-HIT 去冗余后序列数	非标准字符过滤数	长度异常过滤数	最终保留序列数	最终平均长度
GvpA	12156	2078	0	0	2078	129.91aa
GvpC	3020	234	0	1	233	209.54aa
GvpG	8412	3674	0	98	3576	88.07aa
GvpJ	34808	3194	0	59	3135	132.76aa
GvpK	1880	381	0	4	377	107.67aa
GvpN	10132	767	0	9	758	336.93aa
GvpO	14392	1838	0	36	1802	124.22aa
GvpP	1864	226	0	6	220	223.55aa

图 4-1 展示了各类 GVP 蛋白序列的长度统计与极端值过滤结果。图中包括过滤前序列长度的最大值和最小值、基于过滤前均值 ± 3 倍标准差确定的过滤边界，以及过滤后保留序列的平均长度。




图 4-1 不同 GVP 类型序列长度分布图

4.2 片段聚类结果分析

4.2.1 片段生成与 ESM-2 嵌入结果

在清洗后的蛋白序列基础上，本文按照不同 GVP 类型设置滑动窗口长度和步长，将完整蛋白序列切分为局部片段。每个片段作为独立输入序列送入 ESM-2 模型。本文以 ESM-2 35M 为主体，同时使用 ESM-2 150M 和 ESM-2 650M 作为对比模型。

表 4-2 不同 GVP 类型滑动窗口片段生成结果

GVP 类型	最终序列数	窗口长度	步长	生成片段总数
GvpA	2078	30	5	42791
GvpC	233	35	8	5224
GvpN	758	40	8	28558
GvpO	1802	50	5	27873
GvpG	3576	25	5	47244
GvpJ	3135	35	10	32410
GvpK	377	25	4	8038
GvpP	220	40	10	4165

从表 4-2 可以看出，足够的片段总数为后续聚类分析提供了基础样本规模。片段数量越多，HDBSCAN 越容易识别出较稳定的高密度区域；片段数量较少时，聚类结果可能更容易受到局部样本分布影响。

4.2.2 UMAP 降维可视化结果




图 4-2 GvpA 片段嵌入 UMAP 降维结果




图 4-3 GvpC 片段嵌入 UMAP 降维结果

在获得片段级嵌入后，本文使用 UMAP 将高维嵌入映射到二维空间，观察不同片段在表示空间中的分布情况。图 4-2 和图 4-3 展示了 GvpA 和 GvpC 的 UMAP 可视化结果。

从图 4-2 和图 4-3 可以看出，GvpA 和 GvpC 片段在 UMAP 二维空间中均呈现出一定的聚集结构，并非完全随机分散。GvpA 片段分布较为复杂，除中心区域形成多个较密集片段簇外，外围还存在一定数量的离散点，说明 GvpA 片段在整体上具有较明显的表示空间分层特征，同时也存在部分差异较大的局部片段。相比之下，GvpC 片段主要集中在二维空间中部偏下区域，整体分布范围相对较小，但仍可观察到若干局部高密度区域和少量离群片段，提示 GvpC 片段中可能存在重复区域或相似局部序列模式。




图 4-4 其他 GVP 类型片段嵌入 UMAP 降维结果

图 4-4 展示了其他 GVP 类型的 UMAP 子图结果。不同类型蛋白的聚类形态并不完全一致,说明不同 GVP 蛋白在序列组成和片段表示空间结构上存在差异。例如,部分类型形成较为集中的簇状结构,说明其局部片段特征相对稳定;部分类型则表现出更分散的结构,说明其片段差异较大或存在较多难以归类的区域。

4.2.3 HDBSCAN 聚类结果

在 UMAP 降维结果基础上,本文采用 HDBSCAN 对片段进行密度聚类。表 4-3 给出了不同 GVP 类型的 HDBSCAN 聚类统计结果,包括片段总数、噪声比例、最大簇片段数以及通过候选簇数量等指标。

表 4-3 不同 GVP 类型 HDBSCAN 聚类结果统计

GVP 类型	片段总数	噪声比例	最大簇片段数	通过候选簇数
GvpA	42791	0.2207	3602	8
GvpC	5224	0.2092	1398	5
GvpN	28558	0.1955	5199	19
GvpO	27873	0.0761	7221	1
GvpG	47244	0.1566	3738	8
GvpJ	32410	0.1960	3882	6
GvpK	8038	0.2191	644	6
GvpP	4165	0.2574	320	16

从表 4-3 可以看出,不同 GVP 类型的有效簇数量和噪声比例存在差异,但是大多数 GVP 聚类结果的噪声比例都接近 0.2,在合理范围内。有效簇数量反映了 HDBSCAN 在片段嵌入空间中识别出的高密度区域数量,噪声比例则反映了有多少片段未能稳定归入任何簇。

对于无监督候选片段发现任务而言,适当的噪声点是合理的,因为并非所有滑动窗口片段都具有明确的候选功能意义。如果噪声比例过低,可能说明聚类过于宽松,将大量差异较大的片段强行归为同一簇;如果噪声比例过高,则可能说明参数过于保守,导致有效候选簇不足。因此,本文没有单独以噪声比例最低作为最优目标,而是结合有效簇数量、候选簇数量和位置稳定性共同判断聚类结果。

下图 4-5,图 4-6 和图 4-7 分别展示了 GvpA、GvpC 和其他 Gvp 类型的聚类结果。




图 4-5 GvpA 聚类结果




图 4-6 GvpC 聚类结果




图 4-7 其他 GVP 类型聚类结果

对于 GvpA 和 GvpC 等蛋白类型，聚类图 4-5 和 4-6 中可以观察到较明显的主簇分布，说明其部分局部片段在嵌入空间中具有较强的聚集特征。对于其他 GVP 类型，不同蛋白的聚类形态存在一定差异。部分 GVP 类型在 UMAP 空间中形成了相对集中的主要聚类区域，说明这些片段在 ESM-2 嵌入表示中具有较明显的相似性；也有部分 GVP 类型表现为多个较小聚类簇或伴随一定数量噪声点，说明其片段表示分布相对复杂。该现象反映出不同 GVP 蛋白在序列长度、保守程度和局部片段组成上的差异。

总体来看，HDBSCAN 在不同 GVP 类型的片段嵌入空间中均识别出了一定数量的高密度片段簇，并将部分难以稳定归类的片段标记为噪声点。该结果提示，基于 ESM-2 片段嵌入的无监督聚类方法可以从大量滑动窗口片段中获得具有相似表示特征的片段群，为候选功能片段发现提供初步筛选依据。

4.2.4 聚类质量评价结果

为辅助评价不同 GVP 类型的聚类效果，本文计算了轮廓系数、Calinski-Harabasz 指数和 Davies-Bouldin 指数^[26-28]。

从下表 4-4 可以看出，不同 GVP 类型的聚类质量存在一定差异。GvpP、GvpC、GvpA 和 GvpG 的轮廓系数相对较高，分别为 0.5095、0.4587、0.4434 和 0.4436，说明这些蛋白片段在嵌入空间中具有相对清晰的簇归属关系。其中，GvpP 的轮

廓系数最高，表明其有效簇之间的分离程度较好；GvpA 的 Davies-Bouldin 指数最低，为 0.4710，也说明其簇间分离和簇内紧密程度相对较好。GvpG 的 Calinski-Harabasz 指数最高，达到 22889.6304，说明其在当前聚类结果中具有较明显的簇间差异。

表 4-4 不同 GVP 类型聚类质量评价结果

GVP 类型	有效簇数量	轮廓系数	Calinski-Harabasz 指数	Davies-Bouldin 指数
GvpA	262	0.4434	18823.3343	0.4710
GvpC	21	0.4587	4962.4715	0.5053
GvpN	58	0.2852	18443.2117	0.6051
GvpO	80	-0.1185	4482.9646	0.7376
GvpG	141	0.4436	22889.6304	0.5681
GvpJ	161	0.3637	14359.6596	0.5401
GvpK	60	0.3857	7828.9869	0.6057
GvpP	57	0.5095	10841.3735	0.5278

相比之下，GvpO 的聚类质量指标相对较弱，其轮廓系数为-0.1185，Davies-Bouldin 指数为 0.7376，提示该类片段在二维嵌入空间中可能存在较多重叠区域，部分片段的簇归属不够清晰。GvpN 的轮廓系数为 0.2852，低于多数其他 GVP 类型，但其 Calinski-Harabasz 指数较高，说明该类聚类结果可能存在一定簇间差异，但局部簇边界不如 GvpA、GvpC、GvpG 和 GvpP 清晰。GvpJ 和 GvpK 的各项指标处于中间水平，说明其聚类结构具有一定可分性，但仍需要结合后续位置稳定性和跨物种覆盖结果进一步判断候选片段可靠性。

从结果分布看，GvpA、GvpC 等研究基础较明确的蛋白能够形成相对稳定的有效簇，为后续与已知功能区域进行对照提供了基础。

4.3 位置稳定性与跨物种覆盖综合分析

4.3.1 综合统计结果

表 4-5 列出了不同 GVP 类型经过近距离后处理后，按跨物种占比排序得到的前四个候选区域。其中，GvpO 通过筛选并完成后处理后仅保留 1 个候选区域，因此表中仅展示 1 条记录。该表从平均起始位置、窗口长度、CV 值和跨物种占比等方面展示候选区域的综合特征。

从表 4-5 可以看出，不同 GVP 类型的候选区域在序列位置和跨物种覆盖程度上存在差异，说明不同气囊蛋白中的潜在功能片段分布并不完全一致。整体而言，GvpA、GvpG 和 GvpJ 中部分候选区域具有较低的 CV 值，说明这些片段在

不同序列中的起始位置较为集中,位置稳定性较好。例如,GvpA 在 83.02 和 93.66 附近候选区域的 CV 值分别为 0.0434 和 0.0318, GvpG 在 40.10、45.07 和 35.16 附近候选区域的 CV 值也均低于 0.06,说明这些区域在同类蛋白序列中具有较强的位置一致性。

表 4-5 不同 GVP 跨物种占比前四候选区域表

GVP 类型	平均起始位置	窗口长度	CV	跨物种占比
GvpA	83.02	30	0.0434	0.5509
GvpA	65.23	30	0.0841	0.2777
GvpA	16.27	30	0.4240	0.2653
GvpA	93.66	30	0.0318	0.2548
GvpC	215.44	35	0.3529	0.3571
GvpC	225.19	35	0.3455	0.2857
GvpC	102.47	35	0.5883	0.2597
GvpC	76.00	35	0.1751	0.2013
GvpN	218.67	40	0.2193	0.8248
GvpN	114.32	40	0.1796	0.7620
GvpN	135.91	40	0.3064	0.7591
GvpN	50.26	40	0.3618	0.6599
GvpO	71.01	50	0.5191	0.7927
GvpG	13.26	25	0.3667	0.5940
GvpG	40.10	25	0.0490	0.5250
GvpG	45.07	25	0.0415	0.5246
GvpG	35.16	25	0.0573	0.5135
GvpJ	89.68	35	0.1120	0.5205
GvpJ	109.43	35	0.2652	0.5026
GvpJ	49.95	35	0.2369	0.4033
GvpJ	69.98	35	0.1295	0.3642
GvpK	53.05	25	0.4453	0.5673
GvpK	41.28	25	0.4797	0.3868
GvpK	81.97	25	0.3733	0.3725
GvpK	64.63	25	0.1901	0.2636
GvpP	130.38	40	0.4182	0.8855
GvpP	20.17	40	0.5916	0.5802
GvpP	52.01	40	0.2245	0.5725
GvpP	57.95	40	0.1719	0.4122

从跨物种覆盖情况看,GvpN、GvpP 和 GvpO 中部分候选区域表现较为突出。GvpN 的多个候选区域具有较高跨物种占比,其中 218.67 附近区域达到 0.8248,说明该类候选片段在多个物种来源序列中反复出现,具有较好的代表性。GvpP 在 130.38 附近的候选区域跨物种占比达到 0.8855,是表中较高的候选区域之一,

提示该片段可能具有较广泛的分布特征。GvpO 虽然最终仅保留 1 个候选区域，但其跨物种占比为 0.7927，也显示出较好的覆盖范围。

需要注意的是，跨物种占比较高并不一定意味着位置稳定性也较强。例如，GvpP 在 130.38 附近的候选区域跨物种占比较高，但其 CV 值为 0.4182，说明该片段虽然分布范围较广，但在不同序列中的起始位置仍存在一定差异。类似地，部分 GvpC 和 GvpK 候选区域的 CV 值相对较高，说明这些候选片段仍需结合后续注意力分数、MAFFT 保守性和结构预测结果进一步判断。

总体来看，表 4-5 中的候选区域可以大致分为两类：一类是位置稳定性较强的候选片段，如 GvpA 和 GvpG 中的部分区域；另一类是跨物种覆盖较广的候选片段，如 GvpN、GvpP 和 GvpO 中的部分区域。对于仅在单一指标上表现突出的候选区域，后续章节将结合多维度验证结果进行综合评价。

4.3.2 三种 ESM-2 模型结果对比实验

为进一步观察候选区域识别结果是否依赖单一模型表示，本文在主体模型 ESM-2 35M 的基础上，引入 ESM-2 150M 和 ESM-2 650M 进行对比分析。在对比实验中，本文保持滑动窗口策略、UMAP 降维参数、HDBSCAN 聚类参数和候选筛选标准不变，仅替换 ESM-2 模型规模，以观察不同模型表示尺度对片段嵌入分布和候选区域识别结果的影响。通过该对比，可以检验候选片段筛选流程是否过度依赖单一模型，并分析不同参数量模型下候选区域的重复出现情况，从而评价该流程在模型表示尺度上的鲁棒性。




图 4-8 三种 ESM-2 模型候选区域识别结果对比

从图 4-8 可以看出，不同规模 ESM-2 模型在候选区域识别结果上既存在一定一致性，也存在局部差异。图中以 ESM-2 35M 模型的候选区域为参照，因此

35M 模型对应比例均为 100%。对比 150M 和 650M 模型可见, GvpO 在三种模型下均达到 100%匹配, 说明该类蛋白候选区域在不同模型规模下具有较强一致性。GvpJ 和 GvpP 也表现出较高稳定性, 其中 GvpJ 在 150M 和 650M 模型下分别达到 80%和 100%, GvpP 分别达到 90%和 80%, 说明这些类型的候选区域不完全依赖某一特定模型规模, 具有较好的跨模型稳定性。GvpN 和 GvpK 处于中等水平, 二者在 150M 和 650M 模型下均保持相同匹配比例, 分别为 62.5%和 75.0%, 表明其候选区域具有一定稳定性, 但仍受到模型规模变化影响。

相比之下, GvpA、GvpC 和 GvpG 的模型一致性相对较弱。GvpA 在 150M 和 650M 模型下的匹配比例分别为 28.6%和 42.9%, GvpC 分别为 25.0%和 50.0%, GvpG 分别为 40.0%和 60.0%。这说明这些蛋白类型的候选区域对模型规模变化更敏感, 不同模型提取到的片段嵌入特征可能存在差异。造成这种差异的原因可能与不同 GVP 蛋白的序列长度、片段分布、保守区域数量以及局部序列复杂度有关, 因此对于一致性较低的候选区域, 后续仍需结合保守性、结构位置和实验验证进一步确认。

整体来看, ESM-2 35M 模型在计算效率和结果可解释性之间具有较好平衡, 因此本文仍以该模型作为主体分析模型。ESM-2 150M 和 ESM-2 650M 主要用于模型尺度鲁棒性对比。通过在保持后续降维、聚类 and 筛选流程不变的条件下, 仅替换 ESM-2 模型规模, 可以观察候选区域识别结果是否过度依赖单一模型表示。结果表明, 部分候选区域能够在不同模型规模下重复出现, 说明前期筛选结果并非完全依赖单一 ESM-2 模型或单一表示空间; 同时, 不同蛋白类型之间匹配比例存在差异, 也提示气囊蛋白候选区域在模型表示空间中的稳定程度并不完全一致。总体而言, 三模型对比结果支持本文候选片段筛选流程具有一定稳健性, 但对于 GvpA、GvpC 和 GvpG 等一致性相对较弱的类型, 仍需在后续分析中结合更多序列保守性和结构辅助证据进行综合判断。

4.4 多维度验证结果分析

在完成候选簇的位置稳定性、跨物种覆盖和三模型对比分析后, 本文进一步从模型注意力、序列保守性和预测结构三个角度对候选片段进行多维度验证。

4.4.1 ESM-2 注意力分数验证结果

本文提取最终候选区域的 ESM-2 注意力结果, 并统计候选区域对应残基位置的平均注意力分数、注意力标准差和平均百分位。其中, 平均注意力分数用于反映候选片段在模型编码过程中获得的关注程度, 注意力标准差用于描述不同序列中该片段注意力分数的波动情况, 平均百分位用于表示候选片段注意力分数在

对应完整蛋白序列中的相对排序水平。本文主要依据平均注意力分数对候选片段进行排序,并选取每类 GVP 中平均注意力分数较高的前四个候选片段进行展示。GvpO 由于最终候选区域数量较少,因此仅展示 1 个候选片段。

表 4-6 候选片段 ESM-2 注意力分数统计结果

GVP 类型	片段位置	注意力分	注意力标准差	平均百分位
GvpA	25-55	0.3404	0.0582	77.74
GvpA	16-46	0.3058	0.0581	73.28
GvpA	44-74	0.2928	0.0554	70.01
GvpA	83-113	0.2900	0.0506	71.33
GvpC	76-111	0.2257	0.1140	62.94
GvpC	102-137	0.2101	0.1105	57.56
GvpC	225-260	0.1693	0.1026	60.35
GvpC	215-250	0.1309	0.0939	55.45
GvpG	40-65	0.1201	0.0206	83.64
GvpG	45-70	0.1191	0.0205	83.45
GvpG	35-60	0.1185	0.0204	83.35
GvpG	30-55	0.1136	0.0211	82.53
GvpJ	49-84	0.2661	0.0647	66.89
GvpJ	89-124	0.2526	0.0656	65.75
GvpJ	56-91	0.2487	0.0614	63.27
GvpJ	69-104	0.2459	0.0633	63.15
GvpK	41-66	0.3254	0.0601	70.14
GvpK	53-78	0.3245	0.0581	69.98
GvpK	64-89	0.3011	0.0611	67.24
GvpK	81-106	0.2525	0.0706	57.71
GvpN	114-154	0.0683	0.0167	83.45
GvpN	159-199	0.0661	0.0089	86.03
GvpN	135-175	0.0632	0.0097	83.74
GvpN	148-188	0.0624	0.0091	83.72
GvpO	71-121	0.1081	0.0310	71.45
GvpP	32-72	0.3631	0.0507	79.51
GvpP	20-60	0.3484	0.0529	77.67
GvpP	42-82	0.3379	0.0502	76.96
GvpP	47-87	0.3231	0.0477	75.22

由表 4-6 可以看出,不同 GVP 类型候选片段的平均注意力分数存在一定差异。从整体结果看,GvpP、GvpA 和 GvpK 中部分候选片段的注意力分数较高。例如,GvpP 中 32-72、20-60 和 42-82 区域的平均注意力分数分别为 0.3631、0.3484 和 0.3379,平均百分位也均超过 76,说明这些片段不仅在平均注意力分数上较高,而且在对应完整序列内部也处于相对靠前的位置。GvpA 中 25-55 区域的平均注意力分数为 0.3404,平均百分位为 77.74; GvpK 中 41-66 和 53-78 区域的平

均注意力分数分别为 0.3254 和 0.3245，平均百分位接近 70，说明这些区域在模型编码过程中也具有一定的关注强度。

相比之下，GvpN 和 GvpG 候选片段的原始注意力分数相对较低，但其平均百分位较高。例如，GvpN 中 159-199 区域的平均注意力分数为 0.0661，但平均百分位达到 86.03；GvpG 中 40-65、45-70 和 35-60 区域的平均百分位均超过 83。该现象说明，不同 GVP 类型之间的原始注意力分数尺度并不完全一致，原始注意力分数更适合在同一 GVP 类型内部进行排序，而平均百分位可以辅助判断该片段在对应完整序列内部是否相对突出。

GvpC 候选片段的平均注意力分数整体处于中等偏低水平，平均百分位主要集中在 55 到 63 之间，说明这些片段虽然通过了前期聚类 and 位置稳定性筛选，但从模型内部注意力信号来看，其相对突出程度有限。GvpO 仅展示 71-121 区域，该区域平均注意力分数为 0.1081，平均百分位为 71.45，说明其在该类蛋白候选片段中仍具有一定模型注意力支持，但由于候选数量较少，还需要结合后续 MAFFT 保守性和结构分析结果进一步判断。

4.4.2 MAFFT 多序列比对保守性分析结果

本文计算了每个候选片段对应区域的平均保守性分数、保守性标准差和平均百分位。其中，平均保守性分数用于衡量候选片段在多序列比对中的整体保守程度，保守性标准差用于反映该片段在不同序列中的保守性波动情况，平均百分位用于表示该候选片段相对于同一序列其他位置的保守性水平。本文主要依据平均保守性分数对候选片段进行排序，并选取每类 GVP 中平均保守性分数较高的前四个候选片段进行展示。GvpO 由于最终候选区域数量较少，仅展示 1 个候选片段。表 4-7 列出了各 GVP 类型按平均保守性分数排序后的代表性候选片段保守性统计结果。这一排序方式有助于突出不同 GVP 类型中更具序列保守基础的候选区域，为后续结构特征分析和多维度综合评价提供依据。

表 4-7 候选片段 MAFFT 保守性分析结果

GVP 类型	片段位置	参与比序列数	平均保守性分数	保守性标准差	平均百分位
GvpA	25-55	2078	0.8673	0.0098	75.52
GvpA	16-46	2078	0.8521	0.0170	73.69
GvpA	44-74	2078	0.8196	0.0452	68.50
GvpA	83-113	1594	0.6458	0.0396	43.45
GvpC	215-250	94	0.5946	0.1189	66.40
GvpC	102-137	201	0.5362	0.0857	57.43
GvpC	225-260	53	0.5271	0.0686	56.91
GvpC	76-111	206	0.5240	0.0526	56.62

表 4-7 候选片段 MAFFT 保守性分析结果（续）

GVP 类型	片段位置	参与比对序列数	平均保守性分数	保守性标准差	平均百分位
GvpG	49-74	3576	0.5459	0.0248	59.56
GvpG	13-38	3576	0.5261	0.0194	58.43
GvpG	35-60	3576	0.5259	0.0152	57.47
GvpG	30-55	3576	0.5197	0.0164	55.55
GvpJ	49-84	2983	0.5963	0.0504	66.06
GvpJ	60-95	2829	0.5209	0.0542	55.75
GvpJ	69-104	2725	0.4600	0.0477	45.59
GvpJ	89-124	2529	0.3904	0.0477	34.38
GvpK	45-70	350	0.5657	0.0670	51.98
GvpK	67-92	332	0.5461	0.0530	47.95
GvpK	53-78	347	0.5420	0.0656	47.20
GvpK	81-106	301	0.5295	0.0785	47.50
GvpN	162-202	758	0.6956	0.0305	72.15
GvpN	114-154	758	0.6839	0.0571	70.05
GvpN	148-188	758	0.6821	0.0266	71.22
GvpN	135-175	758	0.6703	0.0289	70.19
GvpO	71-121	1396	0.4950	0.0665	63.79
GvpP	32-72	220	0.5993	0.0271	67.00
GvpP	130-170	205	0.5927	0.0447	65.88
GvpP	23-63	220	0.5917	0.0332	65.69
GvpP	42-82	220	0.5758	0.0302	63.18

从表 4-7 可以看出，不同 GVP 类型候选片段的 MAFFT 保守性表现存在一定差异。整体来看，GvpA 和 GvpN 中的部分候选片段具有较高的平均保守性分数。例如，GvpA 中 25-55、16-46 和 44-74 区域的平均保守性分数分别为 0.8673、0.8521 和 0.8196，说明这些区域在同类序列中具有较强的一致性；GvpN 中 162-202、114-154、148-188 和 135-175 区域的平均保守性分数均在 0.67 以上，平均百分位也基本维持在 70 以上，说明这些候选区域在多序列比对结果中表现出较稳定的保守特征。

GvpP 和 GvpC 中的部分候选片段表现为中等程度保守。其中，GvpP 中 32-72、130-170 和 23-63 区域的平均保守性分数接近 0.60，平均百分位均在 65 左右，说明这些区域在序列层面具有一定保守基础；GvpC 中 215-250 区域的平均保守性分数为 0.5946，平均百分位为 66.40，也表现出相对较好的保守性。相比之下，GvpG 和 GvpK 候选片的平均保守性分数整体处于中等水平，说明其候选区域虽然在聚类 and 位置筛选中被保留，但从传统序列比对角度看，保守性支持程度相对有限。

需要注意的是，部分候选片段在 MAFFT 结果中表现出较弱的保守性。例如，GvpJ 中 89-124 区域的平均保守性分数为 0.3904，平均百分位为 34.38，明显低于同类其他候选区域；GvpA 中 83-113 区域虽然前期具有较好的位置稳定性，但其平均保守性分数为 0.6458，平均百分位为 43.45，说明该区域在序列保守性层面的支持不如 GvpA 中前几个候选片段。类似片段不能仅凭聚类结果或位置稳定性直接判断其功能意义，仍需要结合注意力分数和结构分析结果进行综合解释。

MAFFT 保守性分析结果为候选元件筛选提供了重要补充。聚类结果主要反映模型嵌入空间中的片段相似性，而多序列比对能够从实际氨基酸序列层面辅助判断候选片段在不同序列中是否具有较高一致性。

4.4.3 ESMFold 结构预测与 PyMOL 二级结构分析结果

为进一步从结构角度分析候选片段的潜在意义，本文对重点候选片段所在的代表序列进行 ESMFold 结构预测，并使用 PyMOL 对预测结构进行渲染和二级结构统计。每个候选片段最多选取 5 条序列用于结构预测。候选代表序列需满足完整序列长度能够覆盖该候选片段；同时，为减少同一物种重复序列对统计结果的影响，同一候选片段内不重复选择相同物种来源的序列。在此基础上，程序优先选择不同属来源的序列；若不同属序列不足 5 条，则补充同属但不同物种的序列；若可用不同物种序列仍不足 5 条，则按实际可用数量进行结构预测。

本文重点统计候选片段区域中属于 α 螺旋或 β 折叠状态的残基比例，同时记录无规则卷曲比例和含二级结构片段比例。其中，含二级结构片段比例表示同一候选区域的多个代表预测结构中，存在 α 螺旋或 β 折叠残基的结构所占比例。本文主要依据该指标对候选片段进行排序，并选取每类 GVP 中含二级结构片段比例较高的前四个候选片段进行展示。GvpO 由于最终候选区域数量较少，因此仅展示 1 个候选片段。表 4-8 列出了各 GVP 类型候选片段的结构预测与二级结构统计结果。

由表 4-8 可以看出，不同候选片段在预测结构中的二级结构表现存在差异。整体来看，GvpA、GvpN、GvpG、GvpP 等类型中多个候选片段的含二级结构片段比例达到 1.0，说明这些候选区域在多个代表预测结构中均能够观察到 α 螺旋或 β 折叠结构，具有较稳定的局部结构倾向。

表 4-8 候选片段 ESMFold 结构预测与 PyMOL 二级结构统计结果

GVP 类型	片段位置	结构预测数	α 螺旋比例	β 折叠比例	无规则卷曲比例	含二级结构片段比例
GvpA	25-55	5	0.0400	0.5733	0.3867	1.0
GvpA	44-74	5	0.5600	0.0533	0.3867	1.0

表 4-8 候选片段 ESMFold 结构预测与 PyMOL 二级结构统计结果 (续)

GVP 类型	片段位置	结构预测数	α 螺旋比例	β 折叠比例	无规则卷曲比例	含二级结构片段比例
GvpA	93-123	5	0.5800	0.0000	0.4200	1.0
GvpA	16-46	5	0.5533	0.0000	0.4467	1.0
GvpC	102-137	5	0.7086	0.0000	0.2914	0.8
GvpC	76-111	5	0.5829	0.0000	0.4171	0.8
GvpC	215-250	5	0.4857	0.0000	0.5143	0.6
GvpC	225-260	5	0.4057	0.0000	0.5943	0.6
GvpN	264-304	5	0.8100	0.0000	0.1900	1.0
GvpN	73-113	5	0.7300	0.0000	0.2700	1.0
GvpN	209-249	5	0.6800	0.0000	0.3200	1.0
GvpN	85-125	5	0.6550	0.0000	0.3450	1.0
GvpO	71-121	5	0.2240	0.0000	0.7760	0.4
GvpG	30-55	5	0.7760	0.0000	0.2240	1.0
GvpG	35-60	5	0.7600	0.0000	0.2400	1.0
GvpG	40-65	5	0.7600	0.0000	0.2400	1.0
GvpG	45-70	5	0.6560	0.0000	0.3440	1.0
GvpJ	49-84	5	0.5714	0.0000	0.4286	1.0
GvpJ	56-91	5	0.5257	0.0000	0.4743	1.0
GvpJ	89-124	5	0.3029	0.1371	0.5600	0.8
GvpJ	109-144	5	0.3029	0.0686	0.6286	0.8
GvpK	81-106	5	0.7760	0.0000	0.2240	1.0
GvpK	41-66	5	0.5840	0.0000	0.4160	1.0
GvpK	64-89	5	0.6080	0.0000	0.3920	0.8
GvpK	53-78	5	0.5440	0.0000	0.4560	0.6
GvpP	42-82	5	0.9000	0.0000	0.1000	1.0
GvpP	47-87	5	0.8750	0.0000	0.1250	1.0
GvpP	32-72	5	0.8450	0.0000	0.1550	1.0
GvpP	20-60	5	0.8100	0.0000	0.1900	1.0

例如, GvpP 中 42-82、47-87、32-72 和 20-60 区域的含二级结构片段比例均为 1.0, 且 α 螺旋比例较高, 提示该类候选片段可能具有较明显的 α 螺旋结构特征; GvpG 和 GvpN 中的多个候选区域同样表现出较高的含二级结构片段比例, 说明这些区域在结构预测层面具有较好的稳定性支持。

GvpA 候选片段还表现出一定结构类型差异。25-55 区域的 β 折叠比例较高, 而 44-74、93-123 和 16-46 区域主要表现为较高的 α 螺旋比例, 说明 GvpA 不同候选片段可能对应不同局部结构特征。相比之下, GvpC 和 GvpJ 中部分候选片段的含二级结构片段比例为 0.6 或 0.8, 说明这些区域并非在所有代表结构中稳定出现明确二级结构, 可能兼具一定结构倾向和柔性特征。GvpO 中 71-121 区域的含二级结构片段比例为 0.4, 且无规则卷曲比例较高, 提示该区域在预测

结构中稳定二级结构特征相对较弱，后续解释时需要结合保守性和注意力结果综合判断。

需要说明的是，ESMFold 结构预测结果属于计算预测结果，PyMOL 统计得到的二级结构比例也依赖预测结构本身的准确性。因此，本文不将结构预测结果作为功能验证结论，而是将其作为候选片段多维度分析中的结构层面证据。候选元件的真实生物学功能仍需要后续结合突变实验、结构实验或功能实验进一步确认。

4.4.4 多维度验证结果综合分析

综合 ESM-2 注意力分数、MAFFT 多序列比对保守性结果和 ESMFold/PyMOL 结构分析结果可见，不同候选片段获得的证据支持并不完全一致。部分候选片段在模型注意力、序列保守性和二级结构比例等方面均表现较好，具有较高的优先分析价值；也有部分候选片段虽然在聚类结果中较为明显，但在注意力分数、保守性分析或结构特征方面支持相对有限，更适合作为后续观察对象。

表 4-9 汇总了候选片段的多维度验证结果。该表并非依据单一指标排序，而是在每种 GVP 类型内部进行综合排序后，选取得分靠前的 4 个候选片段进行展示。综合排序主要考虑四类信息：一是位置稳定性和跨物种覆盖，其中跨物种占比越高， CV 值越低，对排序越有利；二是 ESM-2 注意力信号，主要依据注意力平均百分位；三是 MAFFT 保守性结果，主要依据保守性平均百分位；四是结构特征，主要依据二级结构占比和含二级结构片段比例。程序先在同一 GVP 类型内部将各类指标转换为相对分位得分，再计算综合排序得分，并选取得分靠前的候选片段进行展示。因此，表 4-9 反映的是候选片段在位置分布、物种覆盖、模型注意力、序列保守性和结构特征等多个维度上的综合表现。

$$S_k = \frac{1}{4} \left[\frac{P_+(SP_k) + P_-(CV_k)}{2} + P_+(A_k) + P_+(M_k) + \frac{P_+(SS_k) + P_+(SSR_k)}{2} \right] \quad (4-1)$$

式中， S_k 表示同一 GVP 类型内第 k 个候选片段的综合排序得分； SP_k 表示该候选片段的跨物种占比； CV 表示该候选片段的起始位置变异系数； A_k 表示注意力平均百分位； M_k 表示 MAFFT 保守性平均百分位； SS_k 表示二级结构占比； SSR_k 表示含二级结构片段比例。 P_+ 表示在同一 GVP 类型内部进行百分位转换时，数值越大得分越高； P_- 表示在同一 GVP 类型内部进行百分位转换时，数值越小得分越高。由于 CV 越小代表候选片段位置越稳定，因此 CV 采用 P_- 处理；跨物种占比、注意力平均百分位、MAFFT 保守性平均百分位、二级结构占比和含二级结构片段比例均采用 P_+ 处理。最终，本文在每种 GVP 类型内部按照综合排序得分 S_k 由高到低排序，并选取得分前四的候选片段进行展示。

从表 4-9 可以看出，不同 GVP 类型中排序靠前的候选片段并不一定在所有指标上同时达到最高值，而是多项证据综合权衡后的结果。因此，综合排序更适合用于确定后续分析和实验验证的优先级，不应被理解为对候选片段功能的直接确认。

表 4-9 候选片段多维度验证结果汇总

GVP 类型	片段位置	跨物种占比	CV	注意力平均百分位	保守性平均百分位	二级结构占比	含二级结构片段
GvpA	25-55	0.2337	0.1231	77.74	75.52	0.6133	1
GvpA	16-46	0.2653	0.424	73.28	73.69	0.5533	1
GvpA	83-113	0.5509	0.0434	71.33	43.45	0.22	0.6
GvpA	44-74	0.2134	0.12	70.01	68.5	0.6133	1
GvpC	76-111	0.2013	0.1751	62.94	56.62	0.5829	0.8
GvpC	102-137	0.2597	0.5883	57.56	57.43	0.7086	0.8
GvpC	215-250	0.3571	0.3529	55.45	66.4	0.4857	0.6
GvpC	225-260	0.2857	0.3455	60.35	57.01	0.4057	0.6
GvpN	135-175	0.7591	0.3064	83.74	70.19	0.45	1
GvpN	114-154	0.762	0.1796	83.45	70.05	0.425	1
GvpN	148-188	0.2978	0.1842	83.72	71.22	0.32	1
GvpN	159-199	0.2292	0.5091	86.03	72.47	0.345	1
GvpO	71-121	0.7927	0.5191	71.45	63.79	0.224	0.4
GvpG	40-65	0.525	0.049	83.64	59.31	0.76	1
GvpG	45-70	0.5246	0.0415	83.45	59.66	0.656	1
GvpG	35-60	0.5135	0.0573	83.35	57.47	0.76	1
GvpG	30-55	0.2366	0.0445	82.53	55.55	0.776	1
GvpJ	49-84	0.4033	0.2369	66.89	66.06	0.5714	1
GvpJ	89-124	0.5205	0.112	65.75	34.38	0.44	0.8
GvpJ	56-91	0.2264	0.2134	63.27	60.38	0.5257	1
GvpJ	69-104	0.3642	0.1295	63.15	45.59	0.2686	0.6
GvpK	41-66	0.3868	0.4797	70.14	54.56	0.584	1
GvpK	64-89	0.2636	0.1901	67.24	48.03	0.608	0.8
GvpK	81-106	0.3725	0.3733	57.71	47.5	0.776	1
GvpK	53-78	0.5673	0.4453	69.98	47.2	0.544	0.6
GvpP	32-72	0.3053	0.3725	79.51	66.97	0.845	1
GvpP	20-60	0.5802	0.5916	77.67	64.67	0.81	1
GvpP	42-82	0.2137	0.2367	76.96	63.18	0.9	1
GvpP	52-92	0.5725	0.2245	73.67	57.88	0.8	1

由表 4-9 可见，不同 GVP 类型中均存在若干多维度证据较为一致的候选片段。例如，GvpG 中 40-65、45-70 和 35-60 等区域具有较高跨物种占比、较低 CV 值、较高注意力平均百分位以及较高二级结构占比，说明这些片段在位置稳定性、模型内部信号和结构特征方面均具有较好支持。GvpN 中 135-175 和 114-154 区

域跨物种占比较高，注意力平均百分位和保守性平均百分位也均处于较高水平，说明这些片段在多个物种来源序列中具有较稳定的候选特征。GvpP 中 32-72、20-60 和 42-82 区域表现出较高注意力平均百分位、较好的保守性百分位和较高二级结构占比，提示这些区域可能具有较明显的局部结构倾向和模型表示支持。

同时，表 4-9 也显示，部分候选片段在不同指标之间存在不一致。例如，GvpA 中 83-113 区域跨物种占比较高且 *CV* 值较低，说明其位置稳定性和物种覆盖表现较好，但其保守性平均百分位和二级结构占比相对不高，提示该区域仍需结合其他证据谨慎解释。GvpO 中 71-121 区域跨物种占比较高，但 *CV* 值较高，且含二级结构片段比例较低，说明该区域虽然具有较广泛的分布范围，但在位置稳定性和结构稳定性方面支持相对有限。类似地，部分 GvpC 和 GvpK 候选片段虽然进入综合排序前列，但其 *CV* 值、保守性百分位或含二级结构片段比例并不完全突出，因此不能仅凭单一指标直接判断其功能意义。

在表 4-9 综合排序结果基础上，本文进一步从排名靠前的候选片段中选取 GvpA 和 GvpC 代表区域进行结构可视化观察，并与已有文献报道的气囊蛋白结构特征进行对照。Huber 等通过冷冻电镜解析了气囊壳层结构，指出 GvpA 是构成气囊壳层的主要结构蛋白，能够自组装形成中空螺旋圆柱状壳体；该研究还识别了 GvpC 与 GvpA 壳层之间的结合关系，认为 GvpC 位于 GvpA 壳层外侧并参与气囊结构加固。因此，本文将综合排序靠前的 GvpA 和 GvpC 候选片段预测结构与文献中的结构示意图进行对比，用于观察候选片段是否与已报道结构特征呈现一致趋势。

在 GvpA 结构对照中，文献报道的 GvpA 单体包含两个 α 螺旋区域和两个 β 折叠区域，其中第一个 α 螺旋区域大致位于 14-22 附近，两个 β 折叠区域分别位于 24-34 和 40-48 附近。本文综合排序靠前的 GvpA 候选片段 16-46 与文献中第一个 α 螺旋区域高度接近，并进一步覆盖后续 β 折叠区域的一部分；另一个候选片段 25-55 则基本覆盖了文献报道的两个 β 折叠区域。对应的 ESMFold 五联图显示，GvpA16-46 在多个代表序列预测结构中呈现 α 螺旋及相邻局部二级结构特征，GvpA25-55 则多数表现出 β 折叠相关构象。该结果说明，本文识别出的 GvpA 候选片段在序列位置上与已有实验结构研究报道的局部二级结构区域具有较好对应关系。已有研究认为，这些螺旋和折叠区域与 GvpA 壳层骨架形成、气囊壁层有序装配及结构稳定有关。因此，本文候选片段与上述区域的对应关系可作为其结构合理性的参考，但其具体功能仍需后续实验进一步验证。




图 4-9 文献中 GvpA 二级结构特征图^[21]




图 4-10 表 4-9 中 GvpA 候选片段 25-55 的 ESMFold 预测结构五联图





图 4-11 表 4-9 中 GvpA 候选片段 16-46 的 ESMFold 预测结构五联图

在 GvpC 结构对照中, Huber 等指出 GvpC 主要由多个约 33aa 的重复单元组成, 整体预测为 α 螺旋结构, 并通过这些重复 α 螺旋单元结合在 GvpA 壳层外侧, 从而参与气囊壳层的结构加固。若按照每个重复单元约 33aa 进行粗略划分, 则第 1 至第 5 重复单元大致对应 1-33、34-66、67-99、100-132 和 133-165。GvpC76-111 的起始位置 76 更接近第 3 个重复单元起始位置 67, 并覆盖第 3 重复单元后半段及第 4 重复单元前段; GvpC102-137 的起始位置 102 接近第 4 个重复单元起始位置 100, 并覆盖第 4 重复单元主体及第 5 重复单元前段。虽然不同物种 GvpC 重复单元边界可能存在一定偏移, 但这两个候选片段在长度尺度和序列位置上均与 GvpC 重复结构特征相符。

从本文 ESMFold 预测结果可以看出, GvpC76-111 和 GvpC102-137 在多数代表序列中均呈现明显 α 螺旋构象, 与文献中 GvpC 重复单元以 α 螺旋形式参与壳层外侧结合的结构特征具有较好一致性。尤其是 GvpC102-137, 其起始位置更接近 33aa 重复单元的整数倍附近, 且预测结构中 α 螺旋特征较为明显, 提示该区域可能位于或接近 GvpC 重复结构中的相对稳定片段。GvpC76-111 虽然与重复单元边界并非完全重合, 但其片段长度接近单个重复单元, 并覆盖相邻重复单元连接区域, 也表现出较强的 α 螺旋倾向, 说明该区域同样具有一定结构解释价值。

图 4-12 文献中 GvpC 二级结构特征图^[21]




图 4-13 表 4-9 中 GvpC 候选片段 76-111 的 ESMFold 预测结构五联图




图 4-14 表 4-9 中 GvpC 候选片段 102-137 的 ESMFold 预测结构五联图

综合 GvpA 和 GvpC 的结构对照结果可以看出，本文多维度综合排序靠前的部分候选片段，在跨物种覆盖、位置稳定性、模型注意力、序列保守性和二级结构比例等指标上表现较好，并且在序列位置和预测结构特征上与已有实验结构研究报道的相关区域呈现一定对应关系。GvpA 候选片段与文献中涉及气囊壳体骨架装配的螺旋和折叠区域相接近，GvpC 候选片段则与文献报道的重复螺旋单元尺度和结构特征较为一致。上述结果说明，本文构建的“片段嵌入提取—降维聚类—候选筛选—多维度验证”流程不仅能够获得统计意义上的候选片段，也可以为候选区域的结构解释提供参考。但这些结果仍属于计算分析层面的证据，不能替代后续实验验证。

需要说明的是，本文对 GvpA 和 GvpC 代表片段的结构展示，并不是为了证明这些片段已经具有确定功能，而是用于观察综合排序靠前的候选片段是否具有结构层面的合理性。文献结构图提供的是已有实验结构研究中的参考特征，本文结构图则来源于 ESMFold 计算预测结果，二者不能简单等同。由于不同物种、不同序列背景以及预测模型本身均可能造成局部结构差异，因此本文仅将这种结构相似性作为辅助证据。总体来看，GvpA 和 GvpC 候选片段与文献报道结构特征之间呈现一定一致趋势，可为后续实验验证、突变设计和功能分析提供参考。

4.5 数据库原型展示结果

4.5.1 数据库表结构和存储结果

数据库以候选片段记录为核心，每条记录对应一个候选窗口或候选片段，并关联其来源蛋白、所属 GVP 类型、物种信息、片段位置和多维度分析结果。这种结构化存储方式便于后续结果复核、条件筛选和候选功能元件的进一步分析。

表 4-10 列出了数据库中的主要字段，包括蛋白编号、GVP 类型、物种来源、基因名称、候选片段序列、片段起始位置、片段终止位置、聚类编号、*CV* 值、跨物种占比、注意力分数、MSA 保守性结果和二级结构比例等。其中，蛋白编号、GVP 类型和物种来源用于追溯候选片段的来源；片段起始位置和终止位置用于定位候选区域在完整蛋白中的位置；聚类编号用于记录片段在 HDBSCAN 聚类结果中的归属；*CV* 值和跨物种占比用于反映候选簇的位置稳定性和分布广度；注意力分数、MSA 保守性结果和二级结构比例用于存储多维度验证结果。

表 4-10 数据库字段说明

字段名	字段说明
accession	蛋白序列登录号或序列 ID，用于标识具体蛋白序列。
gvp_type	GVP 蛋白类型，如 GvpA、GvpC、GvpN、GvpO、GvpG、GvpJ、GvpK、GvpP。
name_organism	蛋白序列所属物种名称。
json_gene	序列对应的基因名称。
start_pos	候选片段在全长蛋白序列中的起始位置。
end_pos	候选片段在全长蛋白序列中的终止位置。
window_seq	候选片段对应的氨基酸窗口序列。
full_sequence_len	蛋白全长序列长度。
window_len	实际候选片段窗口序列长度。
cluster_species_percent	候选片段所在聚类的跨物种占比，用于反映该片段在不同物种中的分布广度。
cluster_cv_start_position	候选片段起始位置的变异系数，用于衡量片段位置稳定性。
msa_avg_score	候选片段的平均 MSA 保守性得分。
msa_avg_percentile	候选片段 MSA 保守性得分的平均百分位。
attn_avg_attn	候选片段的平均 Attention 得分。
attn_avg_percentile	候选片段 Attention 得分的平均百分位。
ss_has_01	候选片段是否包含二级结构，1 表示包含，0 表示不包含。
ss_alpha_ratio	Alpha 螺旋结构在候选片段中的占比。
ss_beta_ratio	Beta 折叠结构在候选片段中的占比。
ss_flexible_ratio	柔性区域或无规则卷曲结构在候选片段中的占比。
ss_ratio	有序二级结构总占比，通常为 Alpha 螺旋占比与 Beta 折叠占比之和。
ss_sequence_ratio	某个候选片段区域内，有二级结构的序列占该区域结构预测序列总数的比例。

本文数据库不设置单一综合评分字段，而是保存各项分析指标的原始结果或统计结果。该设计有利于保持不同指标的独立解释意义，也便于后续根据不同研究目的进行筛选。例如，当研究者更关注保守片段时，可以优先筛选 MSA 保守性较高的记录；当研究者更关注结构特征时，可以筛选二级结构比例较高的记录；当研究者更关注跨物种普遍性时，可以筛选跨物种占比较高的记录。通过这种方式，数据库不仅能够存储实验结果，也能够支持后续结果复核和候选片段再筛选。

4.5.2 Streamlit 界面展示结果

在 SQLite 数据库基础上，本文使用 Streamlit 构建了气囊蛋白候选元件数据库原型界面。




图 4-15 Streamlit 数据库原型首页 1



图 4-16 Streamlit 数据库原型首页 2

图 4-15 展示了候选片段筛选与详情展示功能，用户可以按照 GVP 类型、物种来源、跨物种占比、注意力分数、MSA 保守性和二级结构比例等条件筛选候选片段。图 4-16 展示了预测结构图片查看功能，界面能够显示对应结构图像。



图 4-17 Streamlit 数据库原型统计页

从图 4-17 可以看出，数据库原型统计页主要展示数据集的基本统计信息，包括候选片段总数、涉及的 GVP 类型数量、包含结构预测结果的记录数量以及可展示图片数量等。

此外，数据库原型还支持结果导入和导出。用户可以将整理好的候选片段 CSV 结果导入数据库，也可以将筛选后的结果导出为 CSV 文件、候选片段 FASTA 文件或完整蛋白 FASTA 文件。对于包含结构图片的记录，界面还可以辅助定位对应的图片文件和 PDB 文件。该功能使数据库原型不仅能够用于展示结果，也能够为后续人工检查、补充分析和实验设计提供数据支持。

第五章 结论与展望

5.1 研究结论

本文围绕气囊蛋白候选功能元件识别问题,构建了一套基于蛋白语言模型的片段级计算分析流程。通过对 GvpA、GvpC、GvpG、GvpJ、GvpK、GvpN、GvpO 和 GvpP 八类气囊相关蛋白序列进行整理、去冗余和清洗,本文形成了可用于嵌入提取、聚类分析和候选片段追溯的标准化数据基础。在此基础上,本文利用 ESM-2 提取滑动窗口片段嵌入,并结合 UMAP 降维和 HDBSCAN 聚类,从大量片段中筛选出具有相似表示特征的候选片段簇。

在候选片段筛选结果基础上,本文结合位置稳定性、跨物种覆盖、ESM-2 注意力分数、MAFFT 多序列比对保守性、ESMFold 结构预测和 PyMOL 二级结构统计等多维度证据,对候选片段进行了综合分析和优先排序,最终得到 29 个优先候选功能区域。其中,部分候选区域在模型关注程度、序列保守性和预测结构位置上呈现较好一致性,GvpA 中 25 - 55、16 - 46 等区域在序列位置和预测结构特征上与文献中已报道的壳体骨架装配相关区域具有一定对应关系;GvpC 中 76 - 111、102 - 137 等区域与已报道的重复片段及外表面稳定相关区域相接近。上述结果说明,多维度证据整合能够提高候选区域筛选结果的解释性。

此外,本文构建了基于 SQLite 和 Streamlit 的轻量化数据库原型,实现了候选片段结果的结构化存储、查询和展示,为后续结果管理和扩展分析提供了基础。总体而言,本文识别得到的片段属于计算预测层面的候选功能区域,不等同于已经过实验验证的功能元件,但可为后续气囊蛋白功能验证、突变设计和工程化改造提供候选对象和数据参考。

5.2 不足与展望

本文仍存在一定局限。首先,候选片段主要来源于公开序列和整理后的代表序列数据,结果可能受到原始数据覆盖范围、序列注释质量和物种分布不均衡等因素影响。虽然本文结合跨物种覆盖、保守性分析和结构预测结果对候选区域进行了多维度证据分析,但所得候选片段仍属于计算预测结果,尚未通过突变实验、蛋白互作实验或结构实验进行直接验证。因此,后续研究可优先选择表 4-9 中综合排序靠前且与已有结构研究相对应的候选片段开展实验验证,例如进行片段删除、定点突变或气囊形成能力检测,从而进一步验证候选区域的功能相关性,并据此修正计算筛选流程。

其次，本文参数设置主要基于经验调整和结果可解释性判断，尚未形成完全自动化的参数优化流程。后续可在计算资源允许的条件下，引入更系统的参数搜索和多模型集成策略，并结合复合体结构预测方法，进一步提高候选片段识别结果的稳定性和解释性。

最后，当前数据库原型仍以本地轻量化展示为主，主要用于候选片段结果的存储、查询和展示。后续可在此基础上扩展为在线数据库，增加版本管理、交互式结构查看、候选片段比对和实验验证结果录入等功能，以提升结果共享和复用价值。

参考文献

- [1] Walsby A E. Gas vesicles[J]. Microbiological Reviews, 1994, 58(1): 94-144.
- [2] Pfeifer F. Distribution, formation and regulation of gas vesicles[J]. Nature Reviews Microbiology, 2012, 10(10): 705-715.
- [3] Pfeifer F. Recent advances in the study of gas vesicle proteins and application of gas vesicles in biomedical research[J]. Life, 2022, 12(9): 1455.
- [4] Lakshmanan A, Farhadi A, Nety S P, et al. Molecular engineering of acoustic protein nanostructures[J]. ACS Nano, 2016, 10(8): 7314-7322.
- [5] Jost A, Pfeifer F. Interaction of the gas vesicle proteins GvpA, GvpC, GvpN, and GvpO of *Halobacterium salinarum*[J]. Frontiers in Microbiology, 2022, 13: 971917.
- [6] Dunton P G, Walsby A E. The diameter and critical collapse pressure of gas vesicles in *Microcystis* are correlated with GvpCs of different length[J]. FEMS Microbiology Letters, 2005, 247(1): 37-43.
- [7] Völkner K V, Jost A, Pfeifer F. Accessory Gvp proteins form a complex during gas vesicle formation of haloarchaea[J]. Frontiers in Microbiology, 2020, 11: 610179.
- [8] Iburg M, Anderson A P, Wong V T, et al. Elucidating the assembly of gas vesicles by systematic protein-protein interaction analysis[J]. The EMBO Journal, 2024, 43(19): 4156-4172.
- [9] Li Z, Shen Q, Usher E T, et al. Phase transition of GvpU regulates gas vesicle clustering in bacteria[J]. Nature Microbiology, 2024, 9(4): 1021-1035.
- [10] Feng R, Lan J, Goh M C, et al. Advances in the application of gas vesicles in medical imaging and disease treatment[J]. Journal of Biological Engineering, 2024, 18(1): 41.
- [11] Shapiro M G, Goodwill P W, Neogy A, et al. Biogenic gas nanostructures as ultrasonic molecular reporters[J]. Nature Nanotechnology, 2014, 9(4): 311-316.
- [12] Bourdeau R W, Lee-Gosselin A, Lakshmanan A, et al. Acoustic reporter genes for noninvasive imaging of microorganisms in mammalian hosts[J]. Nature, 2018, 553(7686): 86-90.
- [13] Hurt R C, Buss M T, Duan M, et al. Genomically mined acoustic reporter genes for real-time in vivo monitoring of tumors and tumor-homing bacteria[J]. Nature Biotechnology, 2023, 41(7): 919-931.

- [14] Hurt R C, Jin Z, Soufi M, et al. Directed evolution of acoustic reporter genes using high-throughput acoustic screening[J]. *ACS Synthetic Biology*, 2024, 13(7): 2215-2226.
- [15] Nyström N N, Jin Z, Bennett M E, et al. Multiplexed ultrasound imaging of gene expression[J]. *Nature Methods*, 2025, 22(12): 2594-2600.
- [16] Rives A, Meier J, Sercu T, et al. Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences[J]. *Proceedings of the National Academy of Sciences*, 2021, 118(15): e2016239118.
- [17] Elnaggar A, Heinzinger M, Dallago C, et al. ProtTrans: Toward understanding the language of life through self-supervised learning[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 44(10): 7112-7127.
- [18] Lin Z, Akin H, Rao R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model[J]. *Science*, 2023, 379(6637): 1123-1130.
- [19] Sievers F, Wilm A, Dineen D, et al. Fast, scalable generation of high-quality protein multiple sequence alignments using Clustal Omega[J]. *Molecular Systems Biology*, 2011, 7(1): 539.
- [20] Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with AlphaFold[J]. *Nature*, 2021, 596(7873): 583-589.
- [21] Huber S T, Terwiel D, Evers W H, et al. Cryo-EM structure of gas vesicles for buoyancy-controlled motility[J]. *Cell*, 2023, 186(5): 975-986.e13.
- [22] Madani A, Krause B, Greene E R, et al. Large language models generate functional protein sequences across diverse families[J]. *Nature Biotechnology*, 2023, 41(8): 1099-1106.
- [23] Schmirler R, Heinzinger M, Rost B. Fine-tuning protein language models boosts predictions across diverse tasks[J]. *Nature Communications*, 2024, 15(1): 7407.
- [24] Anfinsen C B. Principles that govern the folding of protein chains[J]. *Science*, 1973, 181(4096): 223-230.
- [25] Li W, Godzik A. Cd-hit: A fast program for clustering and comparing large sets of protein or nucleotide sequences[J]. *Bioinformatics*, 2006, 22(13): 1658-1659.
- [26] Rousseeuw P J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis[J]. *Journal of Computational and Applied Mathematics*, 1987, 20: 53-65.
- [27] Caliński T, Harabasz J. A dendrite method for cluster analysis[J]. *Communications in Statistics*, 1974, 3(1): 1-27.

- [28] Davies D L, Bouldin D W. A cluster separation measure[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1979, PAMI-1(2): 224-227.
- [29] Katoh K, Standley D M. MAFFT multiple sequence alignment software version 7: Improvements in performance and usability[J]. Molecular Biology and Evolution, 2013, 30(4): 772-780.

附 录

附录 A GvpA 参数敏感性测试参数设置

为检验 GvpA 候选区域识别结果对参数变化的稳定性，本文在原始参数组基础上设置了四组扰动参数，共形成五组参数组合。各组参数设置如表 A-1 所示。

表 A-1 GvpA 参数敏感性测试参数设置

参数组号	窗口长度	步长	UMAP 邻居数	UMAP 最小距离	HDBSCAN 最小簇大小	HDBSCAN 最小样本数
1	30	5	20	0.150	40	12
2	27	4	18	0.135	36	11
3	33	6	22	0.165	44	13
4	30	5	16	0.120	36	11
5	30	5	24	0.180	48	14

其中，参数组 1 为原始参数组；参数组 2 和参数组 3 分别表示整体小幅减小和整体小幅增大；参数组 4 主要用于增强局部结构分辨能力；参数组 5 主要用于提高聚类保守性。

致 谢

大学四年的学习生活即将结束，值此毕业论文完成之际，谨向在课题研究和论文撰写过程中给予我帮助和支持的老师、学校表示诚挚感谢。

首先，衷心感谢我的指导教师宫秀军老师。在论文选题、研究思路、实验分析和论文修改过程中，宫老师给予了耐心指导和宝贵建议，使我能够逐步完善研究内容并顺利完成毕业论文。老师认真负责的态度和严谨的治学精神，也使我受益良多。

感谢天津大学智能与计算学部为我提供了良好的学习环境和成长平台。四年的本科阶段学习使我掌握了人工智能和计算机相关专业知识，也培养了我分析问题和解决问题的能力。本文研究涉及人工智能与生物信息学的交叉内容，对我今后继续学习也具有一定启发意义。

本科阶段结束后，我通过推免将至北京大学其他专业继续学习。未来无论从事何种方向，我都会珍惜在天津大学学习期间获得的知识和训练，继续保持认真踏实的态度，不断提升自己。

最后，感谢家人、同学和朋友在学业上给予我的支持和鼓励。谨以此文作为本科阶段学习生活的总结，也向所有关心和帮助过我的人致以诚挚谢意。